

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

การพัฒนากระบวนการบูรณาการที่สอดคล้องกับสุขภาพและเว็บแอปพลิเคชันที่คิดค้นขึ้นเพื่อผู้ป่วยนอก (Hospital Queue Patient Portal & Smartwatch Health Monitoring) เป็นการวิจัยและพัฒนาเชิงบูรณาการที่ผสมผสานองค์ความรู้จากหลากหลายสาขาวิชาชีพทางวิศวกรรมและวิทยาการสุขภาพเข้าด้วยกัน ได้แก่ วิศวกรรมคอมพิวเตอร์ (Computer Engineering) สถาปัตยกรรมระบบสมองกลฝังตัว (Embedded Systems) การประมวลผลสัญญาณชีวภาพ (Biomedical Signal Processing) อินเทอร์เน็ตของสรรพสิ่งทางการแพทย์ (Internet of Medical Things: IoMT) การประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) การเรียนรู้ของเครื่อง (Machine Learning: ML) ระบบสนับสนุนการตัดสินใจทางคลินิก (Clinical Decision Support Systems: CDSS) สถาปัตยกรรมเว็บแอปพลิเคชันสมัยใหม่ ตลอดจนการออกแบบทางกายภาพและการยศาสตร์ของอุปกรณ์สวมใส่ (Wearable Ergonomic Design)

หัวใจสำคัญเชิงแนวคิดของโครงการนี้ มุ่งเน้นการแก้ไขปัญหา “ช่องว่างวิกฤตระหว่างการรอคอย” (Waiting Deterioration Gap) ของผู้รับบริการในแผนกผู้ป่วยนอก (Outpatient Department: OPD) ซึ่งเป็นจุดอ่อนเรื้อรังของระบบบริการสุขภาพ กล่าวคือ ภายหลังจากผู้ป่วยผ่านการคัดกรองเบื้องต้น ณ จุดลงทะเบียนแล้ว ผู้ป่วยมักต้องนั่งรอพบแพทย์เป็นเวลานานโดยไม่มีการเฝ้าระวังสัญญาณชีพอย่างต่อเนื่อง ในช่วงเวลาดังกล่าว หากเกิดภาวะวิกฤตเฉียบพลัน เช่น ความอึดอัดของออกซิเจนในเลือดลดต่ำลงอย่างรวดเร็ว เกิดภาวะหัวใจเต้นผิดจังหวะ หรือเกิดอุบัติเหตุหกล้มหมดสติ เจ้าหน้าที่อาจไม่สามารถรับรู้เหตุการณ์ได้ทันทั่วทั้งโครงการนี้จึงนำเสนอการนำอุปกรณ์สวมใส่ขนาดเล็กมาตรวจวัดข้อมูลทางสรีรวิทยาอย่างต่อเนื่อง ส่งข้อมูลแบบไร้สายเข้าสู่ระบบสารสนเทศ และประยุกต์ใช้แบบจำลองปัญญาประดิษฐ์เพื่อช่วยประเมินระดับความเร่งด่วนทางคลินิกในลักษณะ AI-assisted Decision Support

อย่างไรก็ตาม เพื่อให้สอดคล้องกับหลักจริยธรรมและมาตรฐานความปลอดภัยของผู้ป่วย (Patient Safety) ระบบปัญญาประดิษฐ์ในโครงการนี้มีได้ทำหน้าที่วินิจฉัยโรค (Clinical Diagnosis) หรือกำหนดผลการจัดลำดับความรุนแรงขั้นสุดท้ายโดยอัตโนมัติ หากแต่ยึดมั่นในสถาปัตยกรรม “มนุษย์เป็นผู้ตัดสินใจหลักในวงจร” (Human-in-the-loop Architecture) ซึ่งกำหนดให้พยาบาลวิชาชีพเป็นผู้ตรวจสอบหลักฐานทางสรีรวิทยาและข้อความอาการสำคัญ พร้อมทั้งเป็นผู้ยืนยัน (Confirm) หรือปรับแก้ (Modify) ระดับความรุนแรงก่อนนำไปคำนวณจัดลำดับคิวพบแพทย์จริง

เพื่อให้ครอบคลุมพื้นฐานทางทฤษฎีและเทคโนโลยีที่เกี่ยวข้องทั้งหมด เนื้อหาในบทนี้จึงจำแนกออกเป็น 12 หัวข้อหลักตามสถาปัตยกรรมของระบบ ได้แก่ (1) ระบบคัดแยกผู้ป่วย 5 ระดับ (2) ทฤษฎีสัญญาณชีพและการประเมินทางสรีรวิทยา (3) เทคโนโลยีอุปกรณ์สวมใส่และเซนเซอร์โฟโตพลีทิสโมกราฟี (4) ทฤษฎีการตรวจจับการเคลื่อนไหวและการหกล้ม (5) การประมวลผลภาษาธรรมชาติสำหรับวิเคราะห์อาการสำคัญ (6) แบบจำลองการเรียนรู้ของเครื่องและการประเมินผล (7) สถาปัตยกรรมปัญญาประดิษฐ์สนับสนุนการตัดสินใจและแนวคิด Human-in-the-loop (8) สถาปัตยกรรมเว็บแอปพลิเคชันและการสื่อสารเครือข่าย (9) ระบบความปลอดภัยข้อมูลสุขภาพและการยืนยันตัวตน (10) สถาปัตยกรรมฐานข้อมูลและการจัดการข้อมูลสุขภาพ (11) การออกแบบโครงสร้างทางวิศวกรรม 3 มิติ และ (12) งานวิจัยที่เกี่ยวข้องและตารางสังเคราะห์วรรณกรรม

2.1 ระบบคัดแยกผู้ป่วย 5 ระดับ (5-Level Triage Systems)

2.1.1 ความหมายและวัตถุประสงค์ของการคัดแยกผู้ป่วย

การคัดแยกผู้ป่วย หรือ “Triage” มีรากศัพท์มาจากภาษาฝรั่งเศส “Trier” ซึ่งหมายถึงการจัดหมวดหมู่หรือการคัดแยก ในบริบททางการแพทย์ การคัดแยกผู้ป่วยเป็นกระบวนการประเมินความเร่งด่วนทางคลินิก (Clinical Urgency) เพื่อจำแนกผู้รับบริการตามระดับความต้องการการดูแลรักษา โดยมุ่งเน้นให้ผู้ป่วยที่มีความเสี่ยงสูง

ภาวะคุกคามต่อชีวิต

หรืออวัยวะสำคัญ

ได้รับการประเมินและการช่วยชีวิตอย่างรวดเร็วกว่าผู้ป่วยที่มีอาการคงที่และสามารถรอรับบริการได้

หลักการสำคัญของการคัดแยกจึงมีได้มุ่งหมายให้ผู้ป่วยทุกคนได้รับการตามลำดับเวลาที่เดินทางมาถึงสถานพยาบาลตามหลักการเข้าก่อน-ออกก่อน (First-Come, First-Served: FCFS) เนื่องจาก FCFS

ขาดความยืดหยุ่นและอาจนำไปสู่ผลลัพธ์ทางคลินิกที่ร้ายแรงหากผู้ป่วยวิกฤตต้องรอคอย แต่เป็นการจัดสรรทรัพยากรทางการแพทย์ (Resource Allocation) ภายใต้ข้อจำกัดด้านบุคลากร สถานที่ อุปกรณ์ และเวลา ให้เหมาะสมกับระดับความรุนแรงของผู้ป่วยอย่างมีประสิทธิภาพสูงสุด

ตามแนวทางคู่มือการคัดแยกผู้ป่วยฉุกเฉิน (MOPH ED. Triage) ของกรมการแพทย์ กระทรวงสาธารณสุข [1] อธิบายว่าระบบการคัดกรอง 5 ระดับ จะพิจารณาความรุนแรงทางคลินิกหรือระดับ Acuity เป็นเกณฑ์หลักสำหรับผู้ป่วยกลุ่มที่มีความเสี่ยงสูง (High Acuity) และพิจารณาความต้องการใช้ทรัพยากรทางการแพทย์เพิ่มเติม (Resource Utilization) สำหรับผู้ป่วยที่มีระดับความรุนแรงลดหลั่นลงมา

แนวคิดดังกล่าวมีความสำคัญอย่างยิ่งต่อโครงการนี้

เนื่องจากระบบสารสนเทศที่พัฒนาขึ้นไม่ได้ออกแบบให้เป็นระบบคิวคงที่

แต่ได้รับการออกแบบให้รองรับสภาวะผู้ป่วยที่อาจเปลี่ยนแปลงในระหว่างการรอรับบริการ

(Dynamic Deterioration) ตัวอย่างเช่น ผู้ป่วยที่ได้รับการประเมินครั้งแรกว่าไม่เร่งด่วน

แต่ในระหว่างรอพบแพทย์มีค่าความอิ่มตัวของออกซิเจนในเลือดลดต่ำลง

หรือมีเหตุการณ์หกล้มหมดสติ

ระบบจะต้องสามารถตรวจจับและแจ้งเตือนพยาบาลเพื่อทำการประเมินซ้ำ (Re-triage)

และปรับลำดับคิวใหม่อย่างทันท่วงที

2.1.2 ดัชนีความรุนแรงในภาวะฉุกเฉิน (Emergency Severity Index)

Emergency Severity Index หรือ ESI เป็นระบบคัดแยกผู้ป่วยฉุกเฉิน 5 ระดับที่ได้รับการพัฒนาและใช้งานอย่างแพร่หลายในโรงพยาบาลทั่วโลก

โดยเฉพาะในสหรัฐอเมริกา พัฒนาโดย Gilboy และคณะ [2] โดย ESI Version 4 แบ่งระดับผู้ป่วยออกเป็น 5 ระดับ (Level 1 ถึง Level 5) ผ่านอัลกอริทึมการตัดสินใจ 4 ขั้นตอน (Decision Points A–D) ดังนี้:

- **จุดตัดสินใจ A (Decision Point A):** ผู้ป่วยต้องการการช่วยชีวิตทันทีหรือไม่ (Immediate Life-saving Intervention) หากต้องการ เช่น หยุดหายใจ คลำชีพจรไม่ได้ หรือหมดสติ จะถูกจัดเป็น ESI Level 1 (Resuscitation)
- **จุดตัดสินใจ B (Decision Point B):** ผู้ป่วยตกอยู่ในภาวะความเสี่ยงสูง มีภาวะสับสนเฉียบพลัน หรือมีความทุกข์ทรมานรุนแรงหรือไม่ (High Risk Situation, Confused/Lethargic/Disoriented, Severe Pain/Distress) หากใช่ จะถูกจัดเป็น ESI Level 2 (Emergent)
- **จุดตัดสินใจ C (Decision Point C):** หากไม่เข้าเกณฑ์ในจุด A และ B จะพิจารณาจำนวนทรัพยากรทางการแพทย์ที่คาดว่าจะต้องใช้ (Predicted Resources) เช่น การตรวจทางห้องปฏิบัติการ การตรวจเอกซเรย์ หรือการให้ยาทางหลอดเลือด โดยแบ่งเป็น 2 ทรัพยากรขึ้นไป (Level 3 - Urgent), 1 ทรัพยากร (Level 4 - Less Urgent) และไม่ต้องการใช้ทรัพยากร (Level 5 - Non-Urgent)
- **จุดตัดสินใจ D (Decision Point D):** ประเมินสัญญาณชีพขั้นวิกฤต (Vital Signs Criteria) ในผู้ป่วยกลุ่ม ESI Level 3 หากสัญญาณชีพผิดปกติรุนแรงตามเกณฑ์อายุ อาจได้รับการพิจารณาปรับระดับขึ้นเป็น ESI Level 2

หลักการของ ESI แสดงให้เห็นว่าการคัดแยกไม่ได้อาศัยสัญญาณชีพเพียงค่าใดค่าหนึ่ง แต่ต้องใช้ข้อมูลหลายแหล่งร่วมกัน เช่น อาการสำคัญ (Chief Complaint) ระดับความรู้สึกตัว ภาวะการหายใจ การไหลเวียนโลหิต และทรัพยากรที่ต้องใช้ สิ่งนี้สอดคล้องกับแนวทางของโครงการที่ผสมรวม Vital Signs ร่วมกับ Chief Complaint และ Rule-based Clinical Criteria แทนการตัดสินใจจากมิติข้อมูลเดียว อย่างไรก็ตาม ESI ได้รับการออกแบบสำหรับห้องฉุกเฉิน

ดังนั้นการนำมาประยุกต์ใช้ในระบบผู้ป่วยนอกของโครงการนี้จึงเป็นการนำ

“หลักการจัดระดับความเร่งด่วน” มาใช้เป็นแนวคิดต้นแบบ มิใช่การอ้างว่าเป็นระบบ ESI ที่ได้รับการรับรองทางคลินิกอย่างเป็นทางการ

2.1.3 MOPH ED. Triage และระบบสี 5 ระดับของกระทรวงสาธารณสุขไทย

สำหรับประเทศไทย กระทรวงสาธารณสุขได้พัฒนาเกณฑ์ MOPH ED. Triage โดยประยุกต์หลักการสากลจาก ESI และ Canadian Triage and Acuity Scale (CTAS) เพื่อให้เหมาะสมกับบริบทระบบสุขภาพของประเทศไทย [1]

ระบบดังกล่าวจำแนกความเร่งด่วนออกเป็น 5 ระดับ โดยกำหนดสัญลักษณ์สีมาตรฐานทางการแพทย์ ได้แก่ สีแดง สีชมพู สีเหลือง สีเขียว และสีขาว สอดคล้องกับระดับ Resuscitation, Emergent, Urgent, Less Urgent และ Non-Urgent ตามลำดับ ดังแสดงในตารางที่ 2.1

ตารางที่ 2.1 ความหมายระดับความรุนแรง 5 ระดับที่นำมาใช้เป็นแนวคิดของโครงการ

ระดับ	รหัสสี	ความหมายโดยสรุปตามเกณฑ์ MOPH	แนวทางการจัดการในโครงการ
1	RED (แดง)	วิกฤต/คุกคามต่อชีวิต (Resuscitation)	ส่งสัญญาณแจ้งเตือนฉุกเฉินทันที ให้พยาบาลประเมินเร่งด่วนที่สุดและจัดลำดับคิวสูงสุด
2	PINK (ชมพู)	ฉุกเฉิน/มีความเสี่ยงสูง (Emergent)	ยกระดับการเฝ้าระวัง แจ้งเตือนพยาบาลเพื่อตรวจสอบและประเมินอย่างรวดเร็ว
3	YELLOW W (เหลือง)	เร่งด่วน (Urgent)	ติดตามสัญญาณชีพอย่างใกล้ชิด และจัดลำดับคิวพบแพทย์ก่อนกลุ่มผู้ป่วยทั่วไป
4	GREEN (เขียว)	ไม่เร่งด่วน (Less Urgent)	สัญญาณชีพคงที่ รอรับบริการตามระบบคิวมาตรฐาน อาการไม่ซับซ้อน
5	WHITE (ขาว)	ไม่ฉุกเฉิน/ทั่วไป (Non-Urgent)	อาการเจ็บป่วยเล็กน้อย รอรับบริการตามลำดับการจัดคิวปกติ

ตารางดังกล่าวใช้เพื่ออธิบายระดับความรุนแรงที่ระบบต้นแบบของโครงการรองรับ
โดยมุ่งเน้นการจัดหมวดหมู่เชิงสถาปัตยกรรม
มิได้มีเจตนาในการทดแทนการคัดแยกโดยดุลยพินิจของบุคลากรทางการแพทย์

2.1.4 Korean Triage and Acuity Scale (KTAS)

Korean Triage and Acuity Scale หรือ KTAS
เป็นอีกหนึ่งตัวอย่างของการพัฒนาระบบคัดแยกผู้ป่วย 5
ระดับที่ปรับให้สอดคล้องกับบริบทบริการสุขภาพของสาธารณรัฐเกาหลี งานวิจัยของ Choi, Ok,
และ An (2019) ได้ทำการประเมินความเที่ยงตรงเชิงพยากรณ์ (Predictive Validity) ของ KTAS
และพบว่าระบบสามารถจำแนกความรุนแรงได้อย่างมีประสิทธิภาพ
แต่ยังคงมีข้อจำกัดด้านความคลาดเคลื่อนของการคัดกรองสูงเกินจริง (Over-triage)
และการคัดกรองต่ำกว่าความเป็นจริง (Under-triage)
จึงจำเป็นต้องมีการทบทวนเกณฑ์และประเมินซ้ำโดยบุคลากรอย่างสม่ำเสมอ [3]

ผลการศึกษาดังกล่าวสะท้อนข้อเท็จจริงสำคัญสำหรับโครงการนี้ว่า
แม้กระทั่งระบบคัดแยกที่พัฒนาขึ้นตามมาตรฐานสากลก็ยังไม่สามารถรับประกันความถูกต้องได้
100% ดังนั้น
ระบบปัญญาประดิษฐ์ที่พัฒนาขึ้นในโครงการนี้จึงต้องไม่ทำหน้าที่เป็นผู้ตัดสินใจขั้นสุดท้าย
แต่ต้องแสดงผลเป็นข้อเสนอแนะพร้อมค่าความเชื่อมั่นเพื่อช่วยสนับสนุนให้บุคลากรทางการแพทย์
ตัดสินใจได้รวดเร็วและแม่นยำยิ่งขึ้น

2.1.5 การประเมินซ้ำแบบพลวัตและการจัดลำดับคิว (Dynamic Re-triage)

การคัดกรองเพียงครั้งเดียว ณ เวลาที่ผู้ป่วยเดินทางมาถึง (Point-in-Time Assessment)
มักไม่เพียงพอสำหรับกรณีที่ผู้ป่วยต้องรอคอยเป็นเวลานาน
สัญญาณชีพและอาการทางคลินิกสามารถแปรเปลี่ยนได้ตลอดเวลา
การติดตามแนวโน้มของข้อมูลทางสรีรวิทยาจึงทำหน้าที่เป็นกลไกเตือนภัยเพื่อนำไปสู่
“การประเมินซ้ำ” (Re-triage)

ในโครงการนี้ แนวคิดการจัดลำดับคิวแบบพลวัต (Dynamic Queue Prioritization) จึงมีใช้การให้คอมพิวเตอร์เปลี่ยนลำดับคิวจากข้อมูลดิบของเซนเซอร์โดยตรง แต่เป็นกระบวนการควบคุมแบบวงรอบปิดตามขั้นตอนดังนี้:

【 สถาปัตยกรรมการประเมินซ้ำแบบพลวัต (Dynamic Re-triage Architecture) 】

อุปกรณ์สวมใส่ (Wearable) → ตรวจสอบความผิดปกติ → ระบบหลังบ้านประมวลผล (Backend Analytics)
→ ปัญญาประดิษฐ์เสนอระดับความรุนแรง (AI Suggested Severity) → แจ้งเตือนพยาบาลวิชาชีพ
→ พยาบาลตรวจสอบและยืนยัน (Nurse Confirmation) → ปรับปรุงลำดับคิวพบแพทย์ (Queue Update)

กระบวนการดังกล่าวช่วยรักษาการรอบสถาปัตยกรรม Human-in-the-loop อย่างเคร่งครัด พร้อมทั้งลดความเสี่ยงจากสัญญาณเตือนผิดพลาด (False Alarms) ของเซนเซอร์และความผิดพลาดของแบบจำลอง Machine Learning

2.2 ทฤษฎีสัญญาณชีพและการประเมินทางสรีรวิทยา

2.2.1 ความสำคัญของสัญญาณชีพและระบบคะแนนเตือนภัยล่วงหน้า

สัญญาณชีพ (Vital Signs) เป็นตัวบ่งชี้ทางสรีรวิทยาพื้นฐานที่สะท้อนการทำงานของระบบสำคัญในร่างกาย ได้แก่ ระบบหัวใจและหลอดเลือด ระบบทางเดินหายใจ และระบบประสาทส่วนกลาง ประกอบด้วย อัตราการเต้นของหัวใจ (Heart Rate: HR) อัตราการหายใจ (Respiratory Rate: RR) ความอิ่มตัวของออกซิเจนในเลือด (Peripheral Oxygen Saturation: SpO₂) ความดันโลหิต (Blood Pressure: BP) และอุณหภูมิร่างกาย (Temperature)

การเปลี่ยนแปลงของสัญญาณชีพมักเกิดขึ้นล่วงหน้าเป็นเวลาหลายชั่วโมงก่อนที่อาการทางคลินิกจะทรุดหนักจนเห็นได้ชัด จึงได้มีการพัฒนาระบบคะแนนเตือนภัยล่วงหน้า (Early Warning Score: EWS) เพื่อรวมสัญญาณชีพหลายตัวแปรเข้าเป็นดัชนีชี้วัดความเสี่ยงรวม ระบบ National Early Warning Score 2 (NEWS2) ของราชวิทยาลัยอายุรแพทย์แห่งลอนดอน (Royal College of Physicians: RCP) [4] ใช้ตัวแปรหลัก 6 ประเภท ได้แก่ อัตราการหายใจ,

ความถี่ของออกซิเจน, ความดันโลหิตซิสโตลิก, อัตราชีพจร, ระดับความรู้สึกตัว (ACVPU Scale),
อุณหภูมิร่างกาย และการได้รับออกซิเจนเสริม
เพื่อคำนวณระดับความเสี่ยงทางสรีรวิทยาของผู้ป่วย

2.2.2 อัตราการเต้นของหัวใจ (Heart Rate: HR)

อัตราการเต้นของหัวใจ หรือ Heart Rate (HR)
คือจำนวนรอบการบีบตัวของหัวใจในหนึ่งนาที มีหน่วยเป็นครั้งต่อนาที (beats per minute: bpm)
สามารถวัดได้จากคลื่นไฟฟ้าหัวใจ (ECG)
หรือประมาณการจากคลื่นการเปลี่ยนแปลงปริมาตรเลือด (Pulse Wave) ของโฟโตพ्लीทิสโมกราฟี (PPG)

ในกรณีที่สามารถตรวจจับจุดยอดของคลื่นชีพจร (Pulse Peaks) ได้อย่างต่อเนื่อง
หากกำหนดให้ T_{beat} เป็นช่วงเวลาระหว่างชีพจรสองรอบที่อยู่ติดกัน (Peak-to-Peak Interval)
ในหน่วยวินาที จะสามารถคำนวณอัตราการเต้นของหัวใจได้จากสมการ (2.1)

$$HR = \frac{60}{T_{beat}} \quad (2.1)$$

เมื่อ HR แทน อัตราการเต้นของหัวใจ (bpm) และ T_{beat} แทน ช่วงเวลาระหว่างยอดคลื่นชีพจร (วินาที)

นอกจากนี้ ในกรณีที่สัญญาณชีพจรมีสัญญาณรบกวนปะปน
สามารถวิเคราะห์หาอัตราการเต้นของหัวใจผ่านการแปลงฟูเรียร์เร็ว (Fast Fourier Transform: FFT) เพื่อระบุความถี่หลักของชีพจร (Fundamental Pulse Frequency: f_{HR} ในหน่วย Hz)
ได้จากสมการ (2.2)

$$HR = 60 \cdot f_{HR} \quad (2.2)$$

เมื่อ f_{HR} แทน ความถี่หลักของการเต้นของหัวใจในสเปกตรัมสัญญาณ (Hz)

อย่างไรก็ตาม สัญญาณ PPG บนข้อมือมีความไวสูงต่อการเคลื่อนไหว (Motion Artifacts) แรงกดของตัวเรือน และสภาพการไหลเวียนเลือดส่วนปลาย (Peripheral Perfusion) จึงจำเป็นต้องมีระบบประเมินคุณภาพสัญญาณ (Signal Quality Index) ก่อนนำค่าไปใช้งานเสมอ

2.2.3 ความอิ่มตัวของออกซิเจนในเลือดแดงส่วนปลาย (SpO₂)

ความอิ่มตัวของออกซิเจนในเลือดแดงส่วนปลาย (Peripheral Oxygen Saturation: SpO₂) คือร้อยละของโมเลกุลฮีโมโกลบินที่จับกับออกซิเจน (Oxyhemoglobin: HbO₂) ต่อปริมาณฮีโมโกลบินที่สามารถจับกับออกซิเจนได้ทั้งหมดในเลือดแดง เครื่องวัดออกซิเจนปลายนิ้วหรือพัลส์ออกซิมิเตอร์ (Pulse Oximeter) อาศัยความแตกต่างของสัมประสิทธิ์การดูดกลืนแสงระหว่าง Oxyhemoglobin และ Deoxyhemoglobin (RHb) โดยใช้แสงอย่างน้อยสองความยาวคลื่น ได้แก่ แสงสีแดง (Red Light: ความยาวคลื่นประมาณ 660 nm) และแสงอินฟราเรด (Infrared Light: ความยาวคลื่นประมาณ 880–940 nm) [6], [7]

สัญญาณ PPG ที่ตรวจวัดได้จะถูกแยกออกเป็น 2 องค์ประกอบ ได้แก่ องค์ประกอบกระแสสลับ (AC Component) ซึ่งเกิดจากการเปลี่ยนแปลงปริมาตรเลือดตามจังหวะการบีบตัวของหัวใจ (Pulsatile Blood Flow) และองค์ประกอบกระแสตรง (DC Component) ซึ่งสะท้อนการดูดกลืนแสงของเนื้อเยื่อ กระดูก เลือดดำ และปริมาตรเลือดพื้นฐาน จากนั้นนำมาคำนวณอัตราส่วนคู่ (Ratio of Ratios: R) ดังแสดงในสมการ (2.3)

$$R = \frac{AC_{red}/DC_{red}}{AC_{IR}/DC_{IR}} \quad (2.3)$$

เมื่อ AC_{red} และ DC_{red} แทน องค์ประกอบกระแสสลับและกระแสตรงของสัญญาณแสงสีแดง ตามลำดับ และ AC_{IR} และ DC_{IR} แทน องค์ประกอบกระแสสลับและกระแสตรงของสัญญาณแสงอินฟราเรด ตามลำดับ

ค่า R ที่คำนวณได้ จะถูกนำไปแปลงเป็นค่าความอิ่มตัวของออกซิเจน (SpO₂) ผ่านเส้นโค้งเทียบมาตรฐาน (Calibration Curve) ดังแสดงในสมการ (2.4)

$$SpO_2 = f(R) \approx A - B \cdot R \quad (2.4)$$

เมื่อ f(R) แทน ฟังก์ชันเทียบมาตรฐานเชิงประจักษ์ และ A, B แทน ค่าคงที่เฉพาะของระบบฮาร์ดแวร์

สมการเชิงเส้น เช่น $SpO_2 \approx 110 - 25R$

มักถูกนำมาใช้อธิบายหลักการทำงานเบื้องต้นในวรรณกรรมทั่วไป อย่างไรก็ตาม ค่าคงที่ A และ B จะต้องได้มาจากการสอบเทียบ (Empirical Calibration) กับเครื่องมือมาตรฐานทางการแพทย์ เนื่องจากคุณลักษณะเชิงแสงจริงจะขึ้นอยู่กับโครงสร้างทางทัศนศาสตร์ (Optical Geometry) คุณลักษณะของไดโอดเปล่งแสง ไฟโตดีเทกเตอร์ สภาพเนื้อเยื่อ และแรงกดของเซนเซอร์ [6], [7]

2.2.4 อัตราการหายใจ (Respiratory Rate: RR)

อัตราการหายใจ (Respiratory Rate: RR)

คือจำนวนรอบการหายใจเข้าและออกในหนึ่งนาที

เป็นหนึ่งในตัวแปรที่มีความไวสูงที่สุดในการตรวจจับภาวะวิกฤตทางคลินิก โดยเกณฑ์ NEWS2 กำหนดให้อัตราการหายใจ 12–20 ครั้งต่อนาทีเป็นช่วงปกติสำหรับผู้ใหญ่ [4]

การตรวจวัดอัตราการหายใจโดยทั่วไปอาศัยการขยับของทรวงอกหรือเซนเซอร์วัดการไหลของอากาศ ในระบบอุปกรณ์สวมใส่ สามารถประมาณการอัตราการหายใจจากสัญญาณ PPG ได้ เนื่องจากการหายใจทำให้เกิดการมอดูเลตในสัญญาณ PPG สามารถรูปแบบ ได้แก่ การแปรผันของเส้นฐาน (Baseline Wandering) การแปรผันของแอมพลิจูด (Amplitude Modulation) และการแปรผันของช่วงเวลาระหว่างยอดคลื่นชีพจร (Frequency Modulation) ทั้งนี้ การประมาณค่าอัตราการหายใจจาก PPG จำเป็นต้องใช้อัลกอริทึมการกรองสัญญาณขั้นสูงและการสอบเทียบเฉพาะ จึงไม่ควรใช้การคำนวณแบบสัดส่วนคงที่ เช่น $HR/4$ มาอ้างว่าเป็นค่าที่ตรวจวัดได้จริง

2.2.5 ความดันโลหิตและการประมาณค่าความดันโลหิตแบบไร้ปลอกแขน

ความดันโลหิต (Blood Pressure: BP) ประกอบด้วย ความดันโลหิตซิสโตลิก (Systolic Blood Pressure: SBP) ซึ่งเป็นความดันสูงสุดขณะหัวใจบีบตัว และความดันโลหิตไดแอสโตลิก (Diastolic Blood Pressure: DBP) ซึ่งเป็นความดันต่ำสุดขณะหัวใจคลายตัว มีหน่วยเป็นมิลลิเมตรปรอท (mmHg)

เครื่องวัดความดันโลหิตแบบใช้ปลอกแขนพองลม (Cuff-based Sphygmomanometer) ถือเป็นเครื่องมือมาตรฐานในการวัดความดันโลหิต ส่วนอุปกรณ์สวมใส่แบบไร้ปลอกแขน (Cuffless BP) มักประมาณการความดันโลหิตจากรูปร่างของคลื่นชีพจร (Pulse Wave Analysis:

PWA) หรือความเร็วการเคลื่อนที่ของคลื่นชีพจร (Pulse Transit Time: PTT และ Pulse Arrival Time: PAT)

ซึ่งเป็นการอนุมานทางอ้อมและจำเป็นต้องมีการสอบเทียบเทียบกับค่าความดันมาตรฐานอย่างสม่ำเสมอ

สมาคมความดันโลหิตสูงแห่งยุโรป (European Society of Hypertension: ESH) ได้ออกข้อเสนอนะในการตรวจสอบความถูกต้องของอุปกรณ์วัดความดันโลหิตแบบไร้ปลอกแขน (Stergiou et al., 2023) โดยระบุว่าความแม่นยำของ Cuffless BP มีความซับซ้อนสูง ขึ้นอยู่กับความเสถียรของการสอบเทียบ ตำแหน่งของอุปกรณ์ การเปลี่ยนแปลงของหลอดเลือด และการเคลื่อนไหว จึงต้องระมัดระวังในการนำไปใช้เพื่อการวินิจฉัยโรค [9] ดังนั้น ในโครงการนี้จึงกำหนดให้นิยามข้อมูลดังกล่าวเป็น “Estimated BP” หรือ “BP Trend” เพื่อเป็นข้อมูลสนับสนุนการเฝ้าระวัง มิใช่ค่าความดันโลหิตเพื่อการวินิจฉัยโรคขั้นสุดท้าย

2.2.6 ดัชนีช็อก (Shock Index: SI)

ดัชนีช็อก หรือ Shock Index (SI)

คืออัตราส่วนทางสรีรวิทยาระหว่างอัตราการเต้นของหัวใจกับความดันโลหิตซิสโตลิก

ดังแสดงในสมการ (2.5)

$$SI = \frac{HR}{SBP} \quad (2.5)$$

เมื่อ SI แทน ดัชนีช็อก (ไร้หน่วย), HR แทน อัตราการเต้นของหัวใจ (bpm) และ SBP แทน ความดันโลหิตซิสโตลิก (mmHg)

Rady และคณะ (1994) ได้ศึกษาการใช้ Shock Index ในผู้ป่วยแผนกฉุกเฉินและพบว่า ค่า SI สามารถสะท้อนภาวะความผิดปกติของระบบไหลเวียนโลหิต (Hemodynamic Instability) และการลดลงของปริมาตรเลือดที่ปั๊มออกจากหัวใจในแต่ละครั้ง (Left Ventricular Stroke Volume) ได้เร็วกว่าการพิจารณาค่า HR หรือ SBP เพียงค่าใดค่าหนึ่งเดี่ยวๆ โดยค่าปกติของ SI อยู่ในช่วง 0.5–0.7 หากค่า SI สูงกว่า 0.9 จะบ่งชี้ถึงความเสี่ยงต่อภาวะช็อกและการเสียชีวิตที่เพิ่มขึ้น [5]

ค่า SI จึงถูกนำมาใช้เป็นหนึ่งในดัชนีแจ้งเตือนความเสี่ยง (Risk Triggers) ของระบบโครงการนี้ อย่างไรก็ตาม ค่า SI > 0.9 มิได้หมายถึงการวินิจฉัยภาวะช็อกโดยอัตโนมัติ

เนื่องจากอัตราการเต้นของหัวใจและความดันโลหิตสามารถได้รับอิทธิพลจากปัจจัยอื่น เช่น ยารักษาโรค อายุ ความเครียด หรือภาวะหัวใจเต้นผิดจังหวะ

2.2.7 ระบบคะแนนเตือนภัยล่วงหน้าแห่งชาติ (National Early Warning Score 2: NEWS2)

NEWS2

เป็นเกณฑ์มาตรฐานระดับสากลในการรวมสัญญาณชีพหลายตัวแปรเพื่อประเมินระดับความรุนแรงของการเจ็บป่วยเฉียบพลัน โดยระบบจะกำหนดคะแนนตั้งแต่ 0 ถึง 3 ตามระดับความเบี่ยงเบนของสัญญาณชีพออกจากช่วงค่าปกติ ดังแสดงในตารางที่ 2.2

ตารางที่ 2.2 ตัวอย่างช่วงคะแนน NEWS2 สำหรับพารามิเตอร์ที่เกี่ยวข้องกับโครงการ

พารามิเตอร์	3 คะแนน	2 คะแนน	1 คะแนน	0 คะแนน	1 คะแนน	2 คะแนน	3 คะแนน
อัตราการหายใจ (ครั้ง/นาที)	≤ 8	-	9–11	12–20	-	21–24	≥ 25
ความอิ่มตัวออกซิเจน SpO ₂ (%)	≤ 91	92–93	94–95	≥ 96	-	-	-
ความดันซิสโตลิก SBP (mmHg)	≤ 90	91–100	101–110	111–219	-	-	≥ 220
อัตราชีพจร HR (ครั้ง/นาที)	≤ 40	-	41–50	51–90	91–110	111–130	≥ 131
อุณหภูมิร่างกาย Temp (°C)	≤ 35.0	-	35.1–36.0	36.1–38.0	38.1–39.0	≥ 39.1	-

ค่าจากตารางที่ 2.2 นำมาใช้เป็นพื้นฐานอ้างอิงทางทฤษฎีในการกำหนดเกณฑ์ทางคลินิก (Rule-based Clinical Thresholds) ทั้งนี้ โครงการนี้ได้อ้างว่าเป็นระบบ NEWS2 ฉบับสมบูรณ์ เนื่องจาก NEWS2 ยังรวมถึงการประเมินระดับความรู้สึกตัว (ACVPU Scale) และการได้รับออกซิเจนเสริม ซึ่งอุปกรณ์สวมใส่ของโครงการนี้ได้ตรวจวัดโดยตรง

2.3 เทคโนโลยีอุปกรณ์สวมใส่และเซนเซอร์โฟโตพลีทิสโมกราฟี

2.3.1 อุปกรณ์สวมใส่ทางการแพทย์และอินเทอร์เน็ตของสรรพสิ่งทางการแพทย์

อุปกรณ์สวมใส่ (Wearable Devices)

คืออุปกรณ์อิเล็กทรอนิกส์ขนาดเล็กที่สามารถสวมใส่แนบกับร่างกายและทำงานได้อย่างต่อเนื่องในระหว่างการดำเนินชีวิตประจำวัน เมื่อนำมาเชื่อมต่อเข้ากับเครือข่ายสื่อสารไร้สาย จะกลายเป็นส่วนหนึ่งของระบบอินเทอร์เน็ตของสรรพสิ่งทางการแพทย์ (Medical Internet of Things: IoMT)

Haghi, Thurow, และ Stoll (2017)

อธิบายว่าอุปกรณ์สวมใส่ในระบบการแพทย์ทำหน้าที่เชื่อมโยงระหว่างเซนเซอร์ตรวจวัด

อุปกรณ์พกพา แอปพลิเคชัน และระบบฐานข้อมูลสุขภาพ

เพื่อสร้างระบบเฝ้าระวังสุขภาพระยะยาว [19] ขณะที่ Islam และคณะ (2015)

ได้นำเสนอภาพรวมสถาปัตยกรรม IoT สำหรับการดูแลสุขภาพที่ประกอบด้วย 4 ระดับชั้นหลัก

ได้แก่ Sensing, Networking, Data Processing และ Healthcare Applications [18]

ในโครงงานนี้ นาฬิกาข้อมืออัจฉริยะทำหน้าที่เป็น Physical/Edge Layer

ทำการตรวจวัดสัญญาณชีวภาพ ประมวลผลขั้นต้น และส่งข้อมูลผ่าน Wi-Fi

เข้าสู่ระบบหลังบ้านเพื่อแสดงผลบนหน้าจอพยาบาล

2.3.2 หลักการ Photoplethysmography

Photoplethysmography หรือ PPG เป็นเทคนิคการตรวจวัดทางทัศนศาสตร์แบบไม่รุกราน

(Non-invasive Optical Technique)

เพื่อตรวจวัดการเปลี่ยนแปลงปริมาตรเลือดในหลอดเลือดฝอยส่วนปลาย (Microvascular Bed)

ของเนื้อเยื่อ โดยใช้ไดโอดเปล่งแสง (LED) ส่องผ่านผิวหนัง และโฟโตดีเทกเตอร์ (Photodetector)

วัดปริมาณแสงที่สะท้อนกลับหรือส่องผ่าน [6]

สำหรับอุปกรณ์สวมใส่บนข้อมือ จะใช้เทคนิคโฟโตพลีทิสโมกราฟีแบบสะท้อน

(Reflectance PPG) โดย LED

และโฟโตดีเทกเตอร์จะถูกติดตั้งอยู่บนระนาบเดียวกันที่ฝ่าหลังของตัวเรือน

แสงจะส่องเข้าไปในเนื้อเยื่อและเกิดการกระเจิง (Scattering) และการดูดกลืน (Absorption)

โดยปริมาณแสงที่สะท้อนกลับมายังตัวรับสัญญาณจะแปรผกผันกับปริมาตรเลือดที่ขยายตัวตามรอบการเต้นของหัวใจ

2.3.3 โมดูลเซนเซอร์ชีวภาพ MAX30102

MAX30102 เป็นโมดูลเซนเซอร์ชีวภาพแบบรวมวงจร (Integrated Pulse Oximetry and Heart-Rate Biosensor Module) ของ Analog Devices ประกอบด้วย แหล่งกำเนิดแสง LED สีแดง (ความยาวคลื่น 660 nm) แหล่งกำเนิดแสง LED อินฟราเรด (ความยาวคลื่น 880 nm) โฟโตดีเทกเตอร์ประสิทธิภาพสูง วงจรชดเชยแสงแวดล้อม (Ambient Light Cancellation: ALC) ตัวแปลงสัญญาณอนาล็อกเป็นดิจิทัล (ADC) ความละเอียด 18 บิต ตัวกรองสัญญาณดิจิทัล และอินเทอร์เฟซการสื่อสารแบบ I²C ในแพ็คเกจขนาดกะทัดรัด 14 พิน [7]

จุดเด่นของ MAX30102 คือการใช้พลังงานต่ำมาก (โหมดประหยัดพลังงานใช้กระแสเพียง 0.7 μ A) และเปิดโอกาสให้ผู้พัฒนาสามารถเข้าถึงข้อมูลดิบ (Raw Optical Samples) ของทั้งแสงสีแดงและแสงอินฟราเรดผ่านบัฟเฟอร์ FIFO ขนาด 32 ตัวอย่าง ทำให้สามารถพัฒนาอัลกอริทึมการกรองสัญญาณรบกวนและประเมินคุณภาพสัญญาณตามต้องการได้อย่างยืดหยุ่น อย่างไรก็ตาม ค่าที่ได้จากเซนเซอร์ต้องผ่านการสอบเทียบเชิงประจักษ์และการกรองสัญญาณอย่างถูกต้องก่อนนำไปใช้งาน

2.3.4 ชิปประมวลผลฮับเซนเซอร์ชีวภาพ MAX32664 Biometric Sensor Hub

MAX32664 เป็นไมโครคอนโทรลเลอร์ตรวจวัดสัญญาณทางชีวภาพที่กินพลังงานต่ำมาก (Ultra-Low Power Biometric Sensor Hub) ซึ่งติดตั้งเฟิร์มแวร์และอัลกอริทึมการประมวลผลสัญญาณชีวภาพมาให้ภายในตัว ทำหน้าที่ติดต่อสื่อสารกับเซนเซอร์ฮอปติคัล (เช่น MAX30102) ประมวลผลและคำนวณสัญญาณชีพ จากนั้นส่งผลลัพธ์ที่ประมวลผลแล้วกลับมายังไมโครคอนโทรลเลอร์หลักผ่านโปรโตคอล I²C [8]

MAX32664 มีสายการผลิตย่อย (Firmware Variants) หลายรุ่น ซึ่งออกแบบมาเพื่อการใช้งานเฉพาะที่แตกต่างกัน ได้แก่:

- **Version A:** ออกแบบสำหรับการวัดอัตราการเต้นของหัวใจและ SpO₂ ที่บริเวณนิ้วมือ (Finger HR/SpO₂)
- **Version B:** ออกแบบสำหรับการวัดอัตราการเต้นของหัวใจที่ข้อมือ (Wrist HR)
- **Version C:** ออกแบบสำหรับการวัดอัตราการเต้นของหัวใจและ SpO₂ ที่ข้อมือหรือใบหู (Wrist/Ear HR & SpO₂)
- **Version D:** ออกแบบสำหรับการวัดอัตราการเต้นของหัวใจ, SpO₂ และการประมาณความดันโลหิต (Estimated BP) บริเวณนิ้วมือ ในการออกแบบระบบทางวิศวกรรม

จึงจำเป็นต้องระบุรุ่นของเฟิร์มแวร์และตำแหน่งการวัดให้ตรงกัน โดยเฉพาะอย่างยิ่ง

ฟังก์ชันการประมาณค่าความดันโลหิตใน Version D

ซึ่งระบุคุณลักษณะการวัดไว้สำหรับตำแหน่งนิ้วมือ

จึงไม่ควรอ้างว่าเป็นความดันโลหิตที่ข้อมือโดยตรงหากยังไม่ได้ผ่านการสอบเทียบและทดสอบความถูกต้องเฉพาะของระบบ

2.3.5 ดัชนีคุณภาพสัญญาณ (Signal Quality Index: SQI)

สัญญาณ PPG บนอุปกรณ์สวมใส่มีความไวต่อการรบกวนจากการเคลื่อนไหว (Motion Artifacts) อย่างยิ่ง การแกว่งแขน การสั่นไหวของสายรัด หรือแรงกดที่เปลี่ยนไปสามารถทำให้รูปคลื่นบิดเบือนจนส่งผลให้อัลกอริทึมตรวจจับยอดคลื่นผิดพลาด ดัชนีคุณภาพสัญญาณ (Signal Quality Index: SQI) จึงเป็นกลไกสำคัญที่ใช้ประเมินว่าสัญญาณในช่วงเวลานั้นมีความน่าเชื่อถือเพียงพอที่จะนำไปคำนวณสัญญาณชีพหรือไม่ โดย SQI สามารถนิยามเป็นฟังก์ชันของหลายปัจจัยดังแสดงในสมการ (2.6)

$$SQI = f(A_{AC}, D_{DC}, \text{Noise}, \text{Motion}, \text{Contact}) \quad (2.6)$$

เมื่อ A_{AC} แทน แอมพลิจูดของคลื่นชีพจร, D_{DC} แทน ระดับเส้นฐานของสัญญาณ, Noise แทน ระดับสัญญาณรบกวนความถี่สูง, Motion แทน ระดับการเคลื่อนไหวจากเซนเซอร์ความเฉื่อย และ Contact แทน สถานะการแนบสัมผัสผิวหนัง

ไม่มีสูตร SQI สากสูตรเดียวที่ตายตัวสำหรับทุกระบบ ดังนั้น ค่าขีดเริ่มเปลี่ยน (Thresholds)

และค่าน้ำหนักที่นำมาใช้ในโครงงานนี้จึงต้องระบุเป็นค่าพารามิเตอร์การออกแบบระบบทางวิศวกรรม (Design Parameters) มิใช่ค่าคงที่มาตรฐานทางการแพทย์

2.3.6 การตรวจจับการแนบสัมผัสผิวหนัง (Skin-Contact Detection)

กลไกตรวจจับการแนบสัมผัสผิวหนังทำหน้าที่ตรวจสอบว่าเซนเซอร์รอบปติคอลถูกสวมใส่แนบกับผิวหนังของผู้ป่วยจริงหรือไม่

วิธีการพื้นฐานสามารถตรวจสอบจากระดับแรงดันไฟตรงของแสงอินฟราเรด (IR_DC)

เนื่องจากเมื่อเซนเซอร์อยู่ห่างจากผิวหนังหรือถูกถอดวางไว้

รูปแบบการสะท้อนกลับของแสงจะลดลงอย่างชัดเจน

ระบบสามารถกำหนดสถานะการสัมผัสได้ตามสมการ (2.7)

$$Contact = \begin{cases} 1, & IR_{DC} \geq T_{contact} \\ 0, & IR_{DC} < T_{contact} \end{cases} \quad (2.7)$$

เมื่อ $Contact = 1$ แทน เซนเซอร์แนบสัมผัสผิวหนัง, $Contact = 0$ แทน ไม่ได้สัมผัสผิวหนัง และ $T_{contact}$ แทน ค่าขีดเริ่มเปลี่ยนแรงดันที่ได้จากการทดลองเชิงประจักษ์

การตรวจจับการสัมผัสผิวหนังช่วยป้องกันมิให้ระบบนำค่าสัญญาณรบกวนจากการวางน

าฬิกาบนโต๊ะหรือการถือในมือไปคำนวณผิดพลาดว่าเป็นสัญญาณชีพของผู้ป่วย

2.3.7 การกรองและลดทอนสัญญาณรบกวนจากการเคลื่อนไหว

อีกแนวทางสำคัญในการเพิ่มความเสถียรของสัญญาณ

คือการนำข้อมูลจากเซนเซอร์วัดความเร่ง (Accelerometer)

มาใช้เป็นสัญญาณอ้างอิงของการเคลื่อนไหว (Reference Motion Signal)

ในช่วงเวลาใดที่พบว่าผู้ป่วยมีการขยับแขนหรือเคลื่อนไหวอย่างรวดเร็ว (ความเร่งสูงผิดปกติ)

ระบบจะลดระดับความเชื่อมั่นของสัญญาณชีพลง

หรือระงับการส่งสัญญาณชีพช่วงนั้นชั่วคราวเพื่อป้องกันการเกิด False Alarms

ชิปประมวลผล MAX32664 มีสถาปัตยกรรมที่รองรับการรับข้อมูลความเร่งจาก Accelerometer เข้ามาประมวลผลร่วมเพื่อทำ Motion-artifact Compensation

ในเฟิร์มแวร์บางรุ่น [8] แนวคิดนี้เป็นเหตุผลสำคัญที่โครงการเลือกติดตั้งเซนเซอร์ MPU-6050 ร่วมในระบบ

เพื่อให้สามารถใช้ข้อมูลการเคลื่อนไหวทั้งในการตรวจจับการหกล้มและประเมินคุณภาพของสัญญาณ PPG ควบคู่กัน

2.3.8 ไมโครคอนโทรลเลอร์ Seeed Studio XIAO ESP32-C3

Seed	Studio	XIAO	ESP32-C3
เป็นบอร์ดไมโครคอนโทรลเลอร์ขนาดเล็กที่ใช้ชิปประมวลผล ESP32-C3 ซึ่งเป็นสถาปัตยกรรม RISC-V 32-bit Single-Core ความถี่สัญญาณนาฬิกาสูงสุด 160 MHz ประกอบด้วยหน่วยความจำ SRAM ขนาด 400 KB, Flash Memory 4 MB รองรับการเชื่อมต่อเครือข่ายไร้สาย Wi-Fi มาตรฐาน IEEE 802.11 b/g/n (2.4 GHz) และ Bluetooth Low Energy 5.0 (BLE) [24]			

บอร์ด XIAO ESP32-C3 มีขนาดทางกายภาพเพียง 21 × 17.8 มม. ทำให้เหมาะอย่างยิ่งสำหรับการรวมเข้ากับโครงสร้างตัวเรือนนาฬิกาข้อมือที่มีพื้นที่จำกัด นอกจากนี้ ชิยังมีอินเทอร์เฟซ I²C สำหรับเชื่อมต่อกับเซนเซอร์ MAX30102/MAX32664 และ MPU-6050 รวมถึงตัวแปลง ADC สำหรับตรวจวัดระดับแรงดันแบตเตอรี่

2.4 ทฤษฎีการตรวจจับการเคลื่อนไหวและการหกล้ม

2.4.1 หน่วยวัดความเฉื่อย (Inertial Measurement Unit: IMU)

หน่วยวัดความเฉื่อย	(Inertial Measurement Unit: IMU)
เป็นเซนเซอร์อิเล็กทรอนิกส์ที่ใช้วัดความเร่งเชิงเส้นและความเร็วเชิงมุมของการเคลื่อนที่ เซนเซอร์ MPU-6050 รวมเอาเซนเซอร์วัดความเร่ง 3 แกน (Tri-axial Accelerometer) และไจโรสโคป 3 แกน (Tri-axial Gyroscope) เข้าไว้ในชิปตัวเดียวกัน [11]	
โดยข้อมูลความเร่งเชิงเส้นเขียนแทนด้วยเวกเตอร์	$\mathbf{a} = [a_x, a_y, a_z]$
และความเร็วเชิงมุมเขียนแทนด้วยเวกเตอร์	$\boldsymbol{\omega} = [\omega_x, \omega_y, \omega_z]$

2.4.2 ขนาดเวกเตอร์ความเร่งรวม (Signal Vector Magnitude: SVM)

เพื่อให้สามารถตรวจวัดขนาดของการเคลื่อนไหวรวมโดยไม่ขึ้นกับทิศทางการวางตัวของเซ็นเซอร์ในพิภพ 3 มิติ จึงคำนวณค่าขนาดเวกเตอร์ความเร่งรวม (Signal Vector Magnitude: SVM) ดังแสดงในสมการ (2.8)

$$SVM = \sqrt{a_x^2 + a_y^2 + a_z^2} \quad (2.8)$$

เมื่อ SVM แทน ขนาดเวกเตอร์ความเร่งรวม (g) และ a_x , a_y , a_z แทน ค่าความเร่งในแนวแกน X, Y และ Z ตามลำดับ

ในภาวะที่อุปกรณ์อยู่นิ่งภายใต้แรงโน้มถ่วงของโลก ค่า SVM จะมีค่าคงที่ใกล้เคียง 1.0g เมื่อเกิดการตกหรือทิ้งตัวลงอย่างอิสระ (Free-fall) ค่า SVM จะลดลงเข้าใกล้ 0g และเมื่อเกิดการกระทบกับพื้น (Impact) ค่า SVM จะพุ่งสูงขึ้นอย่างรวดเร็ว

2.4.3 ข้อจำกัดของระบบตรวจวัดแบบเกณฑ์เดียว (Single Threshold)

ระบบตรวจจับการหกล้มที่ใช้เงื่อนไขตรวจสอบเพียงเกณฑ์เดียว เช่น $SVM > T_{\text{impact}}$ มักประสบปัญหาการแจ้งเตือนผิดพลาด (False Positive) สูงมาก เนื่องจากกิจกรรมในชีวิตประจำวัน (Activities of Daily Living: ADL) เช่น การนั่งลงบนเก้าอี้อย่างรวดเร็ว การกระโดด การตบมือ หรือการเหวี่ยงแขน สามารถสร้างค่าความเร่งสูงสุดที่เกินกว่าเกณฑ์ได้เช่นเดียวกับการล้มจริง

Mubashir, Shao, และ Seed (2013)

ได้ทบทวนเทคโนโลยีการตรวจจับการหกล้มและสรุปว่า

ระบบอุปกรณ์สวมใส่จำเป็นต้องใช้ข้อมูลการเคลื่อนไหวแบบหลายเงื่อนไข (Multi-parameter Criteria) ร่วมกับการตรวจวัดลำดับเวลา เพื่อแยกแยะการหกล้มจริงออกจากกิจกรรมประจำวันได้อย่างมีประสิทธิภาพ [10]

2.4.4 การตรวจจับการหกล้มแบบหลายขั้นตอนด้วยไฟไนต์สเตตแมชีน

โครงสร้างทางกายภาพของเหตุการณ์หกล้มประกอบด้วยลำดับขั้นตอนทางสรีรวิทยาที่เกิดขึ้นต่อเนื่องกัน ได้แก่:

1. Stage 1 (Pre-fall / Free-fall):การสูญเสียการทรงตัวและการทิ้งตัวลงอย่างอิสระ ค่า SVM จะลดลงต่ำกว่า 0.5g

2. Stage 2 (Impact Peak):การกระทบกับพื้นผิวอย่างรุนแรง ค่า SVM จะพุ่งสูงเกินกว่า 2.5g ในช่วงเวลาสั้นๆ (ภายใน 100–300 ms)

3. Stage 3 (Post-impact Posture Change):การเปลี่ยนทิศทางการวางตัวของร่างกายอย่างกะทันหัน ซึ่งสะท้อนผ่านการเปลี่ยนแปลงของแกนความเร่ง

4. Stage 4 (Prolonged Inactivity):การนอนนิ่งบนพื้นหลังจากกระทบเป็นระยะเวลาหนึ่ง (เช่น นิ่งนานเกินกว่า 5 วินาที)

โครงการนี้จะพัฒนาอัลกอริทึมการตรวจจับการหกล้มด้วยไฟไนต์สเตตแมชีน (Finite State Machine: FSM) 4 ขั้นตอน ดังแสดงในสมการ (2.9)

$NORMAL \rightarrow FREE_FALL \rightarrow IMPACT \rightarrow INACTIVITY \rightarrow FALL_CONFIRMED$ (2.9)

หากลำดับเหตุการณ์ไม่ครบถ้วนตามช่วงเวลาที่กำหนด (Timeout) ระบบจะเปลี่ยนสถานะกลับสู่ NORMAL ทันที ค่าขีดเริ่มเปลี่ยน เช่น Free-fall < 0.5g, Impact > 2.5g และ Inactivity 5 วินาที จัดเป็นพารามิเตอร์การออกแบบที่ได้จากการทดลองของโครงการ มีใช้ค่ามาตรฐานสัมบูรณ์ทางทฤษฎี

2.4.5 การประเมินประสิทธิภาพระบบตรวจจับการหกล้ม

การประเมินประสิทธิภาพของระบบตรวจจับการหกล้มใช้เมทริกซ์ความสับสน (Confusion Matrix) ประกอบด้วย ผลบวกจริง (True Positive: TP หมายถึง ล้มจริงและตรวจพบ), ผลบวกเท็จ (False Positive: FP หมายถึง ไม่ล้มแต่แจ้งว่าล้ม), ผลลบจริง (True Negative: TN หมายถึง ไม่ล้มและไม่แจ้งเตือน) และ ผลลบเท็จ (False Negative: FN หมายถึง ล้มจริงแต่ตรวจไม่พบ) โดยมีตัวชี้วัดสำคัญดังนี้:

$$Sensitivity = \frac{TP}{TP+FN} \times 100 \quad (2.10)$$

เมื่อ Sensitivity แทน ความไวในการตรวจจับการหกล้ม (%)

$$Specificity = \frac{TN}{TN+FP} \times 100 \quad (2.11)$$

เมื่อ Specificity แทน ความจำเพาะของระบบในการคัดกรองกิจกรรมปกติ (%)

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \times 100 \quad (2.12)$$

เมื่อ Accuracy แทน ความถูกต้องรวมของระบบในการจำแนกเหตุการณ์ (%)

สำหรับระบบความปลอดภัยของผู้ป่วย ค่า Sensitivity มีความสำคัญสูงสุด เนื่องจากผลลบเท็จ (FN) หมายถึงการปล่อยให้ผู้ป่วยที่หกล้มไม่ได้รับความช่วยเหลือ ขณะเดียวกันต้องรักษาค่า Specificity ให้สูงเพื่อป้องกันภาวะเหนื่อยล้าจากสัญญาณเตือน (Alarm Fatigue) ของพยาบาล

2.5 การประมวลผลภาษาธรรมชาติสำหรับวิเคราะห์อาการสำคัญ

2.5.1 ข้อมูลอาการสำคัญทางคลินิก (Chief Complaint)

อาการสำคัญ (Chief Complaint) คือข้อความสั้นที่บันทึกคำบอกเล่าของผู้ป่วยถึงเหตุผลหลักในการมารับบริการที่โรงพยาบาล เช่น “เจ็บแน่นหน้าอก หายใจไม่ออก ร้าวไปที่กราม” หรือ “มีไข้สูง หนาวสั่น อ่อนเพลียมา 3 วัน” แม้ว่าจะเป็นข้อความสั้น แต่กลับบรรจุข้อมูลสำคัญเกี่ยวกับความรุนแรงของโรค การนำอาการสำคัญเข้าสู่แบบจำลอง Machine Learning จำเป็นต้องผ่านกระบวนการแปลงข้อความภาษาธรรมชาติให้เป็นเวกเตอร์เชิงตัวเลข (Numerical Feature Representation)

2.5.2 การเตรียมข้อมูลข้อความภาษาไทย (Thai Text Preprocessing)

กระบวนการเตรียมข้อความภาษาไทยประกอบด้วยขั้นตอนหลัก ได้แก่ การปรับข้อความให้เป็นมาตรฐาน (Text Normalization), การตัดคำ (Tokenization), การกรองสัญญาณรบกวน (Noise Removal) และการสกัดคุณลักษณะ (Feature Extraction)

สำหรับภาษาไทย ความท้าทายหลักอยู่ที่การเขียนข้อความที่ไม่มีการเว้นวรรคระหว่างคำอย่างชัดเจนเหมือนภาษาอังกฤษ การตัดคำจึงต้องอาศัยพจนานุกรมและแบบจำลองเฉพาะ นอกจากนี้ ข้อควรระวังสูงสุดในบริบททางการแพทย์ คือ “การจัดการคำปฏิเสธ” (Negation Handling) ระบบจะต้องไม่ตัด Stop Words เช่น คำว่า “ไม่”, “ไม่มี”, “ห้าม” หรือ “ไม่ได้”

ออกจากข้อความสับสนสับสน ตัวอย่างเช่น ข้อความ “เจ็บหน้าอก” และ “ไม่เจ็บหน้าอก” หากระบบตัดคำว่า “ไม่” ที่ทั้งสองข้อความจะกลายเป็นเวกเตอร์คุณลักษณะที่เหมือนกันและส่งผลให้โมเดลจำแนกความรุนแรงผิดพลาดอย่างร้ายแรง

2.5.3 แบบจำลอง N-gram

Unigram พิจารณาคำเดี่ยวแยกอิสระ เช่น [“เจ็บ”], [“หน้าอก”], [“หายใจ”] ขณะที่ Bigram พิจารณาคู่คำสองคำที่ปรากฏต่อเนื่องกัน เช่น [“เจ็บหน้าอก”], [“หายใจไม่ออก”], [“ไม่มีไข้”] การใช้ Bigram ร่วมกับ Unigram ช่วยให้ระบบสามารถเก็บรักษาบริบทและความหมายเฉพาะของกลุ่มคำทางการแพทย์ได้ดีกว่าการใช้คำเดี่ยวเพียงอย่างเดียว

2.5.4 การคำนวณค่าน้ำหนักความสำคัญของคำด้วย TF-IDF

Term Frequency-Inverse Document Frequency (TF-IDF) เป็นวิธีทางสถิติที่ใช้วัดความสำคัญของคำในเอกสารเมื่อเทียบกับคลังเอกสารทั้งหมด [12] โดยความถี่ของคำ (Term Frequency: TF) ในข้อความคำนวณได้จากสมการ (2.13)

$$TF(t, d) = \frac{n_{t,d}}{\sum_k n_{k,d}} \quad (2.13)$$

เมื่อ $n_{t,d}$ แทน จำนวนครั้งที่คำ t ปรากฏในข้อความ d และตัวส่วนแทน จำนวนคำทั้งหมดในข้อความ d

ส่วนค่าความถี่ผกผันในคลังเอกสาร (Inverse Document Frequency: IDF) คำนวณได้จากสมการ (2.14)

$$IDF(t) = \log\left(\frac{N}{DF(t)}\right) \quad (2.14)$$

เมื่อ N แทน จำนวนข้อความทั้งหมดในชุดข้อมูล และ $DF(t)$ แทน จำนวนข้อความที่มีคำ t ปรากฏ

ค่าน้ำหนัก TF-IDF สรุปรวมได้จากผลคูณของทั้งสองค่าดังแสดงในสมการ (2.15)

$$TFIDF(t, d) = TF(t, d) \times IDF(t) \quad (2.15)$$

คำที่ปรากฏบ่อยในข้อความหนึ่ง แต่ไม่ปรากฏทั่วไปในทุกข้อความ เช่น “แน่นหน้าอก”, “หมดสติ”, “เหงื่อแตกตัวเย็น” จะได้รับค่าน้ำหนักสูง ซึ่งสะท้อนว่าเป็นคำที่มีคุณค่าเชิงสารสนเทศสูงต่อการจำแนกความรุนแรง

2.5.5 ระบบตรรกะแบบกฎทางคลินิกเพื่อความปลอดภัย (Safety Override)

การพึ่งพาโมเดล Machine Learning เพียงอย่างเดียวอาจก่อให้เกิดความเสี่ยงหากข้อมูลนำเข้ามีลักษณะที่ไม่เคยปรากฏในชุดข้อมูลฝึกสอน

โครงการจึงกำหนดให้มีระบบกฎทางคลินิก (Rule-Based Clinical Logic) ทำหน้าที่เป็นกลไกความปลอดภัยขั้นวิกฤต (Safety Override) ดังแสดงในสมการ (2.16)

$$Rule_{critical} = (SpO_2 < T_1) \vee (SBP < T_2) \vee Keyword_{critical} \vee Fall \quad (2.16)$$

เมื่อ T_1 แทน เกณฑ์ SpO_2 วิกฤต (เช่น $< 92\%$), T_2 แทน เกณฑ์ SBP วิกฤต (เช่น < 90 mmHg), $Keyword_{critical}$ แทน การตรวจพบคำสำคัญวิกฤต และ $Fall$ แทน สถานะการตรวจพบการหกล้ม

หากเงื่อนไข $Rule_{critical}$ เป็นจริง ระบบจะปรับเพิ่มระดับความรุนแรงที่ “เสนอแนะ” สู่ระดับสูงทันที โดยไม่อนุญาตให้แบบจำลอง Machine Learning ปรับลดระดับความรุนแรงลงมา ซึ่งเป็นหลักการสำคัญของการสนับสนุนการตัดสินใจทางคลินิก

2.6 แบบจำลองการเรียนรู้ของเครื่องและการประเมินผล

2.6.1 การจำแนกประเภทแบบมีผู้สอนและลักษณะอันดับ

การจำแนกระดับความเร่งด่วนของโครงการนี้ จัดเป็นปัญหาการจำแนกประเภทแบบมีผู้สอนหลายกลุ่ม (Supervised Multiclass Classification) โดยมีเวกเตอร์คุณลักษณะนำเข้า (Input Feature Vector: X) ที่ผสมรวมระหว่างข้อมูลสรีรวิทยาและข้อความอาการสำคัญ ดังแสดงในสมการ (2.17)

$$X = [HR, SpO_2, SBP, DBP, RR, Temperature, TFIDF_1, \dots, TFIDF_m] \quad (2.17)$$

และมีเป้าหมายผลลัพธ์ (Target Output: y) เป็นระดับความรุนแรง 5 ระดับ ดังแสดงในสมการ (2.18)

$$y \in \{RED, PINK, YELLOW, GREEN, WHITE\} \quad (2.18)$$

ทั้งนี้ ระดับความรุนแรงทั้ง 5 มีลักษณะเป็นข้อมูลเชิงอันดับ (Ordinal Classification) ความผิดพลาดของการทำนายจึงมีผลกระทบทางคลินิกไม่เท่ากัน เช่น การทำนายผู้ป่วย RED ผิดพลาดเป็น PINK (คลาดเคลื่อน 1 ระดับ) ย่อมมีความรุนแรงน้อยกว่าการทำนายผู้ป่วย RED ผิดพลาดเป็น WHITE (คลาดเคลื่อน 4 ระดับ) ซึ่งอาจเป็นอันตรายถึงชีวิต

2.6.2 การถดถอยโลจิสติกหลายกลุ่ม (Multinomial Logistic Regression)

Logistic Regression สำหรับการจำแนกหลายคลาส
คำนวณความน่าจะเป็นของแต่ละคลาสผ่านฟังก์ชันซอฟต์แมกซ์ (Softmax Function)
ดังแสดงในสมการ (2.19)

$$P(y = k | \mathbf{x}) = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}} \quad (2.19)$$

เมื่อ $z_k = \mathbf{w}_k^T \mathbf{x} + b_k$ แทน ผลรวมเชิงเส้นของคลาส k และ $K = 5$ แทน จำนวนคลาสทั้งหมด

จุดเด่นของ Logistic Regression คือความเร็วในการประมวลผล ไม่ซับซ้อน และสามารถตรวจสอบค่าน้ำหนักสัมประสิทธิ์ของแต่ละตัวแปรได้ง่าย
จึงเหมาะสำหรับการใช้เป็นแบบจำลองฐาน (Baseline Model)

2.6.3 เครื่องเวกเตอร์สนับสนุน (Support Vector Machine: SVM)

เครื่องเวกเตอร์สนับสนุน (SVM) มุ่งเน้นการค้นหาระนาบแยกมิติ (Hyperplane) ที่สร้างระยะขอบสูงสุด (Maximum Margin) ระหว่างคลาสข้อมูล [13] สำหรับข้อมูลคุณลักษณะ TF-IDF ที่มีมิติสูงและเบาบาง (High-dimensional Sparse Vector) Linear SVM มักให้ประสิทธิภาพที่ดีเยี่ยมและมีความทนทานต่อปัญหา Overfitting

2.6.4 ป่าสุ่มตัดสินใจ (Random Forest Ensemble)

Random Forest เป็นเทคนิคการเรียนรู้แบบกลุ่ม (Ensemble Learning) ที่สร้างต้นไม้ตัดสินใจ (Decision Trees) จำนวนมากจากชุดข้อมูลย่อยและคุณลักษณะย่อยที่สุ่มขึ้นมา

แล้วรวมผลการทำนายผ่านเสียงส่วนใหญ่ (Majority Voting) [14]
 ข้อดีคือสามารถตรวจจับความสัมพันธ์ไม่เชิงเส้น (Non-linear Interactions)
 ระหว่างสัญญาณชีพและค่าสำคัญได้ดี เช่น กรณีที่ SpO_2 ต่ำ ร่วมกับ HR สูง และพบคำว่า
 “แน่นหน้าอก”

2.6.5 งานวิจัย Machine Learning สำหรับ Triage

Levin และคณะ (2018) ได้พัฒนาแบบจำลองการคัดกรองผู้ป่วยอิเล็กทรอนิกส์ (e-triage) ด้วย Machine Learning และพบว่าสามารถจำแนกความเสี่ยงและพยากรณ์ผลลัพธ์ทางคลินิก (เช่น การรับเข้ารักษาใน ICU หรือการเสียชีวิต) ได้ละเอียดกว่าระบบ ESI ดั้งเดิม [15] สิ่งที่โครงการนี้นำมาประยุกต์ใช้

คือแนวคิดการบูรณาการข้อมูลหลายมิติเพื่อสนับสนุนการคัดกรองความเสี่ยง
 มิใช่การนำโมเดลสำเร็จรูปของโรงพยาบาลเดิมมาใช้งานโดยตรง

2.6.6 เมทริกซ์ความสัมพันธ์และการวิเคราะห์ทิศทางความผิดพลาด

ในการจำแนก 5 ระดับ เมทริกซ์ความสัมพันธ์ขนาด 5×5
 จะแสดงการกระจายตัวของการทำนายที่ถูกต้องบนแนวทแยงมุมหลัก (Diagonal)
 และความผิดพลาดนอกแนวทแยง ในระบบคัดแยกทางการแพทย์
 จำเป็นต้องแยกแยะทิศทางของความผิดพลาดออกเป็น 2 ประเภท:

- **Under-triage:** การประเมินระดับความรุนแรงต่ำกว่าความเป็นจริง เช่น
 ผู้ป่วยวิกฤตถูกทำนายเป็นไม่เร่งด่วน
 ส่งผลให้ผู้ป่วยได้รับการดูแลรักษาล่าช้าและเกิดอันตรายถึงชีวิต
- **Over-triage:** การประเมินระดับความรุนแรงสูงกว่าความเป็นจริง
 ส่งผลให้เกิดการใช้ทรัพยากรทางการแพทย์อย่างสิ้นเปลืองและอาจทำให้ผู้ป่วยอื่นต้องรอ
 คอยนานขึ้น

เนื่องจาก Under-triage มีผลกระทบต่อความปลอดภัยของผู้ป่วยโดยตรง
 การประเมินระบบจึงไม่สามารถพิจารณาจากค่าความถูกต้องรวม (Accuracy) เพียงอย่างเดียวได้

2.6.7 – 2.6.9 ตัวชี้วัดประสิทธิภาพของแบบจำลอง

ความถูกต้องรวม (Overall Accuracy) คำนวณได้จากสมการ (2.20)

$$Accuracy = \frac{\text{Number of Correct Predictions}}{\text{Total Predictions}} \times 100 \quad (2.20)$$

สำหรับแต่ละคลาส i สามารถคำนวณ Precision, Recall และ F1-score ได้จากสมการ (2.21), (2.22) และ (2.23) ตามลำดับ

$$Precision_i = \frac{TP_i}{TP_i + FP_i} \quad (2.21)$$

$$Recall_i = \frac{TP_i}{TP_i + FN_i} \quad (2.22)$$

$$F1_i = 2 \cdot \frac{Precision_i \times Recall_i}{Precision_i + Recall_i} \quad (2.23)$$

ในระบบคัดแยกผู้ป่วย จำเป็นต้องให้ความสำคัญกับค่า Recall ของกลุ่ม RED และ PINK เป็นพิเศษ เพื่อให้มั่นใจว่าระบบสามารถตรวจจับผู้ป่วยวิกฤตได้ครอบคลุมที่สุด นอกจากนี้ยังสามารถประเมินความถูกต้องแบบยอมรับความคลาดเคลื่อนได้ 1 ระดับ (Within-one-level Accuracy) ดังแสดงในสมการ (2.24)

$$Within1 = \frac{1}{N} \sum_{i=1}^N I(|\hat{y}_i - y_i| \leq 1) \quad (2.24)$$

เมื่อ $I(\cdot)$ แทน ฟังก์ชันบ่งชี้ (Indicator Function) ซึ่งมีค่าเท่ากับ 1 เมื่อเงื่อนไขเป็นจริง และเท่ากับ 0 เมื่อเงื่อนไขเป็นเท็จ ทั้งนี้ Within-one-level Accuracy ใช้เพื่อวิเคราะห์แนวโน้มความคลาดเคลื่อน แต่ไม่สามารถนำมาทดแทนค่า Exact Accuracy หรือ Recall ของกลุ่มวิกฤตได้

2.7 สถาปัตยกรรมปัญญาประดิษฐ์สนับสนุนการตัดสินใจและแนวคิด Human-in-the-loop

2.7.1 ปัญญาประดิษฐ์ในฐานะระบบสนับสนุนการตัดสินใจ

ระบบปัญญาประดิษฐ์ในทางการแพทย์มีความอ่อนไหวสูงกว่าระบบทั่วไป องค์การอนามัยโลก (WHO, 2021) ได้วางกรอบแนวทางจริยธรรมและธรรมาภิบาลของปัญญาประดิษฐ์สำหรับระบบสุขภาพ (Ethics and Governance of Artificial Intelligence for Health) โดยเน้นย้ำถึงหลักการสำคัญ 6 ประการ

ได้แก่ การเคารพความเป็นอิสระของมนุษย์ (Autonomy), ความปลอดภัยและสวัสดิภาพ, ความโปร่งใส, ภาระความรับผิดชอบ (Accountability), ความเท่าเทียม และความยั่งยืน [16]

จากหลักการดังกล่าว โครงการนี้จึงกำหนดความสัมพันธ์เชิงสถาปัตยกรรมว่า AI Suggested Severity $\neq$ Final Clinical Decision แต่เป็นไปตามสมการ (2.25)

$$FinalSeverity = NurseConfirmedSeverity \quad (2.25)$$

กล่าวคือ

ผลลัพธ์สุดท้ายที่นำไปใช้งานต้องเป็นระดับความรุนแรงที่ผ่านการยืนยันจากพยาบาลวิชาชีพเท่านั้น

2.7.2 ระดับความรุนแรงที่เสนอแนะโดยปัญญาประดิษฐ์ (AI Suggested Severity)

AI Suggested Severity คือผลลัพธ์ที่ระบบประมวลผลขึ้นจากการผสมรวมระหว่าง Vital Signs, Chief Complaint, แบบจำลอง Machine Learning และ Rule-Based Overrides โดยผลลัพธ์ที่ส่งไปยังหน้าจอของพยาบาลจะประกอบด้วย 3 องค์ประกอบหลัก ได้แก่: (1) ระดับความรุนแรงที่แนะนำ (Suggested Severity), (2) ค่าความเชื่อมั่นของระบบ (System Confidence) และ (3) รายการเหตุผลประกอบทางคลินิก (Explainable Clinical Reasons) เช่น “SpO₂ ต่ำกว่า 92% ต่อเนื่องเกิน 30 วินาที” หรือ “พบคำสำคัญบ่งชี้อาการหายใจลำบาก” เพื่อให้บุคลากรทราบที่มาของการแจ้งเตือน

2.7.3 การยืนยันระดับความรุนแรงโดยพยาบาลวิชาชีพและการจัดคิว

พยาบาลประจำจุดคัดกรองมีอำนาจในการกดปุ่มยืนยันผลตามที่ AI เสนอ (Confirm) หรือทำการแก้ไขปรับเปลี่ยนระดับ (Modify) ตามการตรวจประเมินทางคลินิกจริง โดยระดับความรุนแรงที่ระบบนำไปใช้ในการจัดลำดับคิวพบแพทย์ (Queue Severity) จะผูกโยงกับดุลยพินิจของพยาบาลโดยตรง ดังแสดงในสมการ (2.26)

$$QueueSeverity = NurseConfirmedSeverity \quad (2.26)$$

นี่คือแกนหลักของสถาปัตยกรรม

Human-in-the-loop

ซึ่งป้องกันผลกระทบจากความผิดพลาดของระบบอัตโนมัติได้อย่างสมบูรณ์

2.7.4 ปัญญาประดิษฐ์ที่อธิบายได้ (Explainable AI: XAI)

Amann

และคณะ

(2020)

ได้ศึกษาประเด็นด้านความสามารถในการอธิบายได้ของปัญญาประดิษฐ์ในระบบสุขภาพ

และชี้ให้เห็นว่า XAI มีความสำคัญอย่างยิ่งต่อการสร้างความเชื่อมั่น ความรับผิดชอบ และการยอมรับของบุคลากรทางการแพทย์ [17] ในโครงการนี้

ความสามารถในการอธิบายผลมีได้หมายถึงการแจกแจงสูตรคณิตศาสตร์เชิงลึก

แต่เป็นการแสดงปัจจัยกระตุ้นทางสรีรวิทยา (Vital Triggers) คำสำคัญในข้อความ (Text Triggers) และแนวโน้มของสัญญาณชีพ (Trend Changes)

เพื่อให้พยาบาลสามารถตรวจสอบย้อนกลับไปยังข้อมูลดิบต้นทางได้อย่างรวดเร็ว

2.7.5 การจัดการความไม่แน่นอนของระบบและแบบจำลอง

ระบบจะต้องแยกแยะระหว่าง “ความเชื่อมั่นของเซนเซอร์” (Sensor Signal Quality) และ “ความเชื่อมั่นของแบบจำลอง” (Model Classification Confidence) ออกจากกันอย่างชัดเจน ดังแสดงในสมการ (2.27)

$$Confidence_{system} \neq Confidence_{ML} \quad (2.27)$$

เนื่องจากแบบจำลองอาจมีความเชื่อมั่นในการทำนายสูงบนข้อมูลสัญญาณชีพที่มาจากเซนเซอร์ที่มีสัญญาณรบกวนปะปน (Low SQI) ในกรณีดังกล่าว ระบบจะต้องแสดงสถานะเตือน เช่น “LOW SIGNAL QUALITY – RECHECK REQUIRED” แทนการแสดงผลความรุนแรงที่สร้างความเข้าใจผิดแก่บุคลากร

2.8 สถาปัตยกรรมเว็บแอปพลิเคชันและการสื่อสารเครือข่าย

2.8.1 สถาปัตยกรรม IoMT 5 ระดับชั้น

สถาปัตยกรรมของระบบบูรณาการในโครงการนี้ แบ่งการทำงานออกเป็น 5 ระดับชั้นตามแนวทาง IoT Healthcare Architecture [18] ได้แก่:

- 1. Sensing Layer: เซนเซอร์ออปติคัล MAX30102/MAX32664 และเซนเซอร์วัดความเฉื่อย MPU-6050 ตรวจวัดข้อมูลสรีรวิทยาและการเคลื่อนไหว

- 2. Edge Layer: ไมโครคอนโทรลเลอร์ XIAO ESP32-C3 ทำหน้าที่ประเมินคุณภาพสัญญาณ (SQI), ตรวจจับสนามแม่เหล็ก, ตรวจจับสนามด้วย FSM และจัดเก็บข้อมูลลงแฟลชหน่วย
- 3. Network Layer: การสื่อสารไร้สายผ่าน Wi-Fi 2.4 GHz โดยเข้ารหัสข้อมูลด้วยโปรโตคอล HTTPS/TLS
- 4. Backend Layer: ระบบบริการหลังบ้าน ให้บริการ RESTful API, เชื่อมต่อฐานข้อมูล, วัฏจักรการแจ้งเตือน AI-assisted Triage และคำนวณการจัดลำดับคิว
- 5. Application Layer: เว็บแอปพลิเคชันสำหรับผู้รับบริการ (Patient Portal) และแดชบอร์ดสำหรับพยาบาล (Nurse Dashboard)

2.8.2 ส่วนต่อประสานโปรแกรมประยุกต์แบบ RESTful

REST (Representational State Transfer)

เป็นรูปแบบสถาปัตยกรรมที่ใช้ทรัพยากรเป็นศูนย์กลางในการสื่อสารผ่านโปรโตคอล HTTP/HTTPS ระบบแลกเปลี่ยนข้อมูลในรูปแบบ JSON มาตรฐาน รองรับเมธอดพื้นฐาน ได้แก่ GET สำหรับอ่านข้อมูล, POST สำหรับสร้างข้อมูลใหม่, PUT/PATCH สำหรับแก้ไข และ DELETE สำหรับลบข้อมูล โครงสร้างข้อมูลทางสุขภาพที่ส่งผ่าน API จะประกอบด้วย ตัวระบุอุปกรณ์ (Device ID), ข้อมูลสัญญาณชีพ, เมทาเดตาคุณภาพสัญญาณ และเวลาที่ตรวจวัด (Timestamp)

2.8.3 ความปลอดภัยในการส่งข้อมูลด้วย HTTPS

เนื่องจากข้อมูลสุขภาพจัดเป็นข้อมูลส่วนบุคคลที่มีความอ่อนไหวสูง

การส่งข้อมูลแบบข้อความธรรมดา (Plaintext HTTP) บนเครือข่ายไร้สายสาธารณะจึงเป็นข้อห้ามอย่างเด็ดขาด ระบบจึงบังคับใช้โปรโตคอล HTTPS ร่วมกับการเข้ารหัส Transport Layer Security (TLS) ทั้งในการสื่อสารระหว่าง ESP32 ไปยัง API Server และระหว่างเว็บเบราว์เซอร์ไปยัง API Server เพื่อป้องกันการดักจับข้อมูล (Eavesdropping) และการปลอมแปลงข้อมูลระหว่างทาง (Man-in-the-middle Attack)

2.8.4 กลไกการเรียกดูข้อมูลเป็นระยะ (Client Polling)

กลไกการดึงข้อมูลเป็นระยะ (Client Polling)

คือการกำหนดให้เว็บเบราว์เซอร์ส่งคำขอตรวจสอบข้อมูลสถานะคิวใหม่จากเซิร์ฟเวอร์ตามช่วงเวลาที่กำหนดอย่างสม่ำเสมอ ดังแสดงในสมการ (2.28)

$$t_n = t_0 + n\Delta t \quad (2.28)$$

เมื่อ t_n แทน เวลาที่ส่งคำขอครั้งที่ n , t_0 แทน เวลาเริ่มต้น และ Δt แทน ช่วงเวลาการเรียกดู (Polling Interval)

ในแอปพลิเคชัน Patient Portal ของโครงการนี้ มีการตั้งค่า Polling Interval พื้นฐานไว้ที่ 10,000 มิลลิวินาที (10 วินาที) ข้อดีของ Polling คือความง่ายในการติดตั้งดูแลและความทนทานต่อการขัดข้องของเครือข่าย โดยผู้ใช้สามารถปรับแต่งช่วงเวลาได้ตามความเหมาะสมของปริมาณการใช้งาน

2.8.5 สถาปัตยกรรม Next.js App Router

ส่วนต่อประสานสำหรับผู้ป่วย (Patient Portal) พัฒนบนเฟรมเวิร์ก Next.js 16 (App Router) ซึ่งทำงานร่วมกับ React 19 และ TypeScript 5 สถาปัตยกรรมของระบบถูกจัดระเบียบแบบแบ่งชั้นตามโมดูล ได้แก่ app, features (แยกตามฟังก์ชัน registration, auth, queue, account) และ shared (คอมโพเนนต์และยูทิลิตี้ส่วนกลาง) ซึ่งช่วยให้ระบบมีความเป็นระเบียบ ทนทานต่อข้อผิดพลาด และรองรับการทำงานแบบตอบสนองบนอุปกรณ์พกพาได้อย่างสมบูรณ์

2.8.6 บัฟเฟอร์ข้อมูลออฟไลน์บนอุปกรณ์ขอบ (Store-and-Forward)

ในการใช้งานจริง สัญญาณเครือข่าย Wi-Fi อาจเกิดการหลุดชั่วคราวได้ หากระบบไม่มีกลไกจัดเก็บข้อมูลสำรอง ข้อมูลสัญญาณชีพในช่วงเวลาดังกล่าวจะสูญหายทันที โครงการจึงออกแบบบัฟเฟอร์แบบวงกลม (Circular/Ring Buffer) บนหน่วยความจำของ ESP32 เพื่อเก็บข้อมูลสัญญาณชีพชั่วคราว เมื่อการเชื่อมต่อเครือข่ายกลับมาทำงานปกติ ระบบจะส่งข้อมูลที่สะสมไว้ในบัฟเฟอร์ย้อนหลังกลับไปยังเซิร์ฟเวอร์โดยรักษา Timestamp

ดั้งเดิมไว้

กลไกนี้เรียกว่า

Store-and-Forward

ซึ่งช่วยให้ข้อมูลสรีรวิทยาของผู้ป่วยมีความต่อเนื่องสมบูรณ์

2.9 ระบบความปลอดภัยข้อมูลสุขภาพและการยืนยันตัวตน

2.9.1 ข้อมูลสุขภาพในฐานะข้อมูลส่วนบุคคลอ่อนไหว

ตามพระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล พ.ศ. 2562 (PDPA)

ข้อมูลสุขภาพและข้อมูลชีวภาพจัดอยู่ในกลุ่มข้อมูลส่วนบุคคลที่มีความอ่อนไหวเป็นพิเศษตามมา

ตรา 26 ซึ่งห้ามมิให้เก็บรวบรวม ใช้

หรือเปิดเผยโดยไม่ได้รับความยินยอมโดยชัดแจ้งจากเจ้าของข้อมูล

เว้นแต่เข้าข้อยกเว้นตามกฎหมาย เช่น เพื่อประโยชน์ในการรักษาพยาบาล [23]

ข้อมูลที่เกี่ยวข้องกับโครงการ ได้แก่ เลขประจำตัวประชาชน ข้อมูลการแพทย์ ประวัติการรักษา

และข้อมูลสัญญาณชีพ จึงต้องได้รับการปกป้องด้วยมาตรการทางเทคนิคที่รัดกุมสูงสุด

2.9.2 การออกแบบเพื่อความเป็นส่วนตัว (Privacy by Design)

ระบบยึดมั่นในหลักการ Privacy by Design ประกอบด้วย:

- **Data Minimization:**
จัดเก็บเฉพาะข้อมูลที่จำเป็นต่อการจัดคิวและการเฝ้าระวังทางการแพทย์เท่านั้น
- **Purpose Limitation:**
ใช้ข้อมูลตามวัตถุประสงค์ที่แจ้งแก่ผู้ป่วยในการให้บริการคัดกรองและตรวจรักษา
- **Access Control:** จำกัดการเข้าถึงข้อมูลตามบทบาทหน้าที่ (Role-based Access Control)
- **Auditability:**
เก็บบันทึกประวัติการเข้าถึงและการปรับเปลี่ยนสถานะคิวเพื่อการตรวจสอบย้อนหลัง
- **Secure Credential Storage:** ไม่จัดเก็บรหัสผ่านหรือรหัส PIN ในรูปแบบข้อความธรรมดา แต่ใช้การแฮชแบบทางเดียวที่มีความปลอดภัยสูง

2.9.3 การพิสูจน์ตัวตนและการอนุญาตสิทธิ์ (Authentication & Authorization)

การพิสูจน์ตัวตน (Authentication) คือกระบวนการยืนยันตัวตนว่าผู้ใช้คือใคร ขณะที่การอนุญาตสิทธิ์ (Authorization) คือกระบวนการตรวจสอบว่าผู้ใช้ที่ยืนยันตัวตนแล้วมีสิทธิ์เข้าถึงหรือกระทำการใดในระบบได้บ้าง ในโครงงานนี้ ผู้ป่วยสามารถเข้าถึงได้เฉพาะข้อมูลคิวและสัญญาณชีพของตนเองพยาบาลสามารถดูภาพรวมของผู้ป่วยในความดูแลและยืนยันระดับความรุนแรงได้ ส่วนผู้ดูแลระบบมีสิทธิ์จัดการการตั้งค่าอุปกรณ์

2.9.4 การพิสูจน์ตัวตนด้วยโทเคน (Token-Based Authentication)

เมื่อผู้ป่วยหรือบุคลากรเข้าสู่ระบบสำเร็จ เซิร์ฟเวอร์จะสร้างโทเคนการเข้าถึง (Access Token) ที่ผ่านการลงนามแบบดิจิทัล จากนั้นเว็บเบราว์เซอร์จะแนบโทเคนดังกล่าวไปกับส่วนหัวของคำขอ (HTTP Authorization Header: Bearer <token>) ในการเรียกดูข้อมูลคิวและข้อมูลส่วนตัว ซึ่งช่วยให้ระบบสามารถตรวจสอบสิทธิ์ได้อย่างปลอดภัยโดยไม่ต้องส่งข้อมูลส่วนบุคคลซ้ำซ้อน

2.9.5 ระบบพิสูจน์ตัวตนดิจิทัลภาครัฐ (ThalID)

ThalID เป็นระบบพิสูจน์และยืนยันตัวตนดิจิทัลของกรมการปกครอง กระทรวงมหาดไทย ซึ่งพัฒนาขึ้นตามมาตรฐาน OAuth 2.0 และ OpenID Connect (OIDC) เพื่อทำหน้าที่เป็น Identity Provider (IdP) ให้แก่หน่วยงานภายนอก ในบริบทของโครงงานนี้ ThalID เป็นแนวคิดสำหรับเชื่อมต่อการยืนยันตัวตนของผู้ป่วยโดยไม่ต้องสร้างกระบวนการพิสูจน์ตัวตนใหม่ ทั้งนี้ ในโค้ดของระบบต้นแบบปัจจุบัน ฟังก์ชันการล็อกอินของผู้ป่วยได้รับการจำลองผ่านเลขประจำตัวประชาชนและการทดสอบ API ส่วนการเชื่อมต่อกับระบบ ThalID จริงจัดเป็นส่วนที่ออกแบบรองรับและมีแผนการบูรณาการในอนาคต

2.9.6 การจับคู่อุปกรณ์กับผู้ป่วย (Device-Patient Pairing)

นอกจากระบบพิสูจน์ตัวตนของผู้ใช้งาน อุปกรณ์สวมใส่ IoT จะต้องมีอัตลักษณ์ประจำตัว (Device Identity) และต้องผ่านกระบวนการจับคู่กับผู้ป่วย (Device-Patient Pairing) ก่อนการใช้งานจริง ดังแสดงในสมการ (2.29)

เมื่ออุปกรณ์ถูกผูกโยงเข้ากับรหัสผู้ป่วยอย่างเป็นทางการผ่านจุดคัดกรองแล้ว

เซิร์ฟเวอร์หลังบ้านจึงจะยอมรับข้อมูลโทรมาตร (Telemetry) จากอุปกรณ์ดังกล่าว

ซึ่งช่วยป้องกันการส่งข้อมูลปลอมแปลงจากอุปกรณ์ปลอมปลอมเข้าสู่ระบบคิว

2.10 สถาปัตยกรรมฐานข้อมูลและการจัดการข้อมูลสุขภาพ

2.10.1 แบบจำลองข้อมูลเชิงแนวคิด (Conceptual Data Model)

ระบบของโครงการประกอบด้วยเอนทิตีข้อมูลหลัก ได้แก่ Patient, Device, Vital, Telemetry, Triage, Alert, Queue และ Nurse โดยมีความสัมพันธ์เชิงตรรกะแบบหนึ่งต่อกลุ่ม (One-to-Many: 1:N) เช่น Patient 1:N Vital, Patient 1:N Triage, Patient 1:N Queue และ Device 1:N Telemetry ความสัมพันธ์เหล่านี้เป็นแบบจำลองเชิงแนวคิดที่สามารถนำไปปรับใช้ได้ทั้งบนระบบฐานข้อมูลเชิงสัมพันธ์และฐานข้อมูลแบบ NoSQL

2.10.2 ฐานข้อมูลเชิงสัมพันธ์ (Relational Database)

ฐานข้อมูลเชิงสัมพันธ์จัดเก็บข้อมูลในรูปแบบตาราง (Tables) ประกอบด้วยแถวและคอลัมน์ เชื่อมโยงความสัมพันธ์ด้วยคีย์หลัก (Primary Key: PK) และคีย์นอก (Foreign Key: FK) มีจุดเด่นด้านคุณสมบัติ ACID (Atomicity, Consistency, Isolation, Durability) ซึ่งช่วยรักษาความถูกต้องสมบูรณ์ของข้อมูลทางการแพทย์ได้อย่างเข้มงวด

2.10.3 ฐานข้อมูลเอกสารแบบ NoSQL (Cloud Firestore)

Cloud Firestore เป็นฐานข้อมูลแบบ NoSQL Document-oriented Database ซึ่งจัดเก็บข้อมูลในรูปแบบเอกสาร (Documents) ภายในคอลเลกชัน (Collections) จุดเด่นคือโครงสร้างข้อมูลที่มีความยืดหยุ่นสูง (Flexible Schema) รองรับการขยายตัวในแนวนอน (Horizontal Scalability) และมีฟังก์ชันการชิงโครโนซ์ข้อมูลแบบเรียลไทม์ที่เหมาะสมกับสถาปัตยกรรมคลาวด์ อย่างไรก็ตาม เนื่องจาก Firestore ไม่มี Foreign Key Constraints

การรักษาความปลอดภัยของข้อมูลจึงต้องควบคุมผ่าน

Business

Logic

ในระดับแอปพลิเคชันและกฎความปลอดภัย (Security Rules)

2.10.4 ข้อมูลสัญญาณชีพลักษณะอนุกรมเวลา (Time-Series Vital Data)

ข้อมูลสัญญาณชีพจากอุปกรณ์สวมใส่แตกต่างจากข้อมูลประวัติผู้ป่วยทั่วไป
เนื่องจากมีปริมาณเพิ่มขึ้นอย่างต่อเนื่องตามลำดับเวลา

โดยข้อมูลแต่ละตัวอย่างสามารถเขียนแทนได้ด้วยสมการ (2.30)

$$V_i = (patient, timestamp, HR, SpO_2, \dots) \quad (2.30)$$

การออกแบบโครงสร้างข้อมูลจึงต้องรองรับรูปแบบการสืบค้น (Query Patterns)
ตามช่วงเวลา เช่น “ดึงข้อมูลอัตราการเต้นของหัวใจของผู้ป่วย P001 ในรอบ 30 นาทีล่าสุด”
ทำให้จำเป็นต้องสร้างดัชนีผสม (Composite Index) บนฟิลด์ (patient_id, timestamp)
เพื่อให้การดึงข้อมูลและการแสดงผลเส้นกราฟสัญญาณชีพเป็นไปอย่างรวดเร็ว

2.10.5 นโยบายการคงอยู่และการหมุนเวียนข้อมูล (Data Retention Policy)

เพื่อป้องกันปัญหาฐานข้อมูลมีขนาดใหญ่เกินความจำเป็นและเพื่อสอดคล้องกับหลัก
Data Minimization ระบบจึงกำหนดนโยบายการจัดเก็บข้อมูลออกเป็น 3 ลำดับชั้น: (1) Raw
Telemetry ซึ่งเป็นข้อมูลดิบความถี่สูง จะถูกจัดเก็บไว้ในระยะสั้นเพื่อการตรวจจับความผิดปกติ
(2) Validated Vital Signs ซึ่งผ่านการประเมินคุณภาพแล้ว
จะจัดเก็บไว้ตลอดระยะเวลาที่ผู้ป่วยรับบริการในโรงพยาบาล และ (3) Clinical Audit Records
ซึ่งบันทึกผลการยืนยันระดับความรุนแรงของพยาบาล
จะถูกจัดเก็บไว้ระยะยาวเพื่อการตรวจสอบย้อนหลังตามมาตรฐานเวชระเบียน

2.11 การออกแบบโครงสร้างทางวิศวกรรม 3 มิติ

2.11.1 ความสำคัญของการออกแบบเชิงกลไกและการยศาสตร์

สำหรับอุปกรณ์สวมใส่ทางการแพทย์
การออกแบบตัวเรือนไม่ได้มีหน้าที่เพียงแค่ปกป้องแผงวงจรอิเล็กทรอนิกส์จากสภาพแวดล้อมภายนอกเท่านั้น แต่มีผลกระทบโดยตรงต่อคุณภาพของสัญญาณชีวภาพ (Biomedical Signal Quality)
เนื่องจากการตรวจวัด PPG

อาศัยการแนบสัมผัสทางแสงของเซนเซอร์กับผิวหนังในตำแหน่งและแรงกดที่เหมาะสม
 การออกแบบเชิงกลไกจึงต้องคำนึงถึงตำแหน่งการติดตั้งเซนเซอร์ การยืดหยุ่นวงจร
 การจัดวางแบตเตอรี่ การเว้นระยะสายอากาศ การระบายความร้อน
 และความสะอาดของสายในการสวมใส่

2.11.2 ช่องเปิดทางทัศนศาสตร์และการป้องกันแสงรบกวน (Optical Window)

บริเวณด้านใต้ของตัวเรือนจะต้องมีช่องเปิดทางทัศนศาสตร์ (Optical Window) เพื่อให้
 LED และโฟโตดีเทกเตอร์ของ MAX30102
 สามารถแนบสัมผัสกับผิวหนังข้อมือได้โดยไม่มีสิ่งกีดขวาง นอกจากนี้
 โครงสร้างตัวเรือนรอบเซนเซอร์จะต้องทำจากวัสดุทึบแสงและมีผนังกันทางแสง (Optical Barrier)
 เพื่อป้องกันไม่ให้แสงจาก LED รั่วไหลเข้าไปยังโฟโตดีเทกเตอร์โดยตรงโดยไม่ผ่านเนื้อเยื่อ
 (Optical Crosstalk) และป้องกันแสงสว่างจากภายนอกห้องส่องเข้าไปรบกวนการตรวจวัด

2.11.3 การควบคุมแรงกดสัมผัสผิวหนัง (Contact Pressure Regulation)

หากสายรัดนาฬิกาหลวมเกินไป
 เซนเซอร์จะขยับและทำให้เกิดสัญญาณรบกวนจากการเคลื่อนไหว (Motion Artifacts)
 แต่หากสายรัดแน่นเกินไป
 แรงกดจะไปกดทับหลอดเลือดฝอยส่วนปลายจนทำให้การไหลเวียนเลือดหยุดชะงัก (Vascular Occlusion) และส่งผลให้รูปคลื่นชีพจรผิดเพี้ยน
 ตัวเรือนและสายรัดจึงต้องได้รับการออกแบบให้อยู่ในช่วงแรงกดที่เหมาะสม ดังแสดงในสมการ
 (2.31)

$$P_{min} < P_{contact} < P_{max} \quad (2.31)$$

โดยค่าแรงกดที่เหมาะสมจะต้องได้มาจากการทดลองสวมใส่จริงร่วมกับการประเมินค่าดัชนีคุณภาพ
 พัลส์สัญญาณ (SQI)

2.11.4 เขตปลอดภัยสำหรับสายอากาศวิทยุ (Antenna Keep-out Zone)

ไมโครคอนโทรลเลอร์ ESP32-C3 สื่อสารผ่านคลื่นวิทยุความถี่ 2.4 GHz การมีตัวนำ
 โลหะ ทองแดง หรือก้อนแบตเตอรี่อยู่ใกล้กับสายอากาศรบกวนมากเกินไป

จะทำให้เกิดการลดทอนสัญญาณวิทยุ (RF Attenuation) และทำให้ระยะการส่งสัญญาณสั้นลง การออกแบบแผงวงจร Carrier Board และตัวเรโซนาเตอร์จึงต้องกำหนดเขตปลอดภัยตัวนำ (Antenna Keep-out Zone) บริเวณขอบบอร์ดอย่างเคร่งครัด

2.11.5 เทคโนโลยีการขึ้นรูปด้วยการเพิ่มเนื้อวัสดุ (Additive Manufacturing)

เทคโนโลยีการพิมพ์ 3 มิติแบบหลอมฉีดเส้นพลาสติก (Fused Deposition Modeling: FDM) ถูกนำมาใช้ในการขึ้นรูปตัวเรโซนาเตอร์แบบ โดยใช้วัสดุพลาสติก เช่น PLA (Polylactic Acid) หรือ PETG (Polyethylene Terephthalate Glycol) ซึ่งมีจุดเด่นด้านความแข็งแรง น้ำหนักเบา และต้นทุนการผลิตต่ำ ทั้งนี้ ในระดับอุปกรณ์ต้นแบบการวิจัย พลาสติกดังกล่าวเหมาะสำหรับการทดสอบตำแหน่งทางกายภาพและการยศาสตร์เบื้องต้น แต่ยังไม่ควรนำไปอ้างว่าเป็นวัสดุทางการแพทย์ที่ผ่านการรับรองความปลอดภัยต่อผิวหนัง (Medical Skin-Safe Material) จนกว่าจะผ่านการผลิตด้วยกระบวนการมาตรฐานอุตสาหกรรม

2.12 งานวิจัยที่เกี่ยวข้องและตารางสังเคราะห์วรรณกรรม

2.12.1 งานวิจัยการติดตามสัญญาณชีพต่อเนื่องในโรงพยาบาล

Downey และคณะ (2018) ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบ (Systematic Review) เพื่อเปรียบเทียบระหว่างการติดตามสัญญาณชีพแบบต่อเนื่อง (Continuous Vital Sign Monitoring) กับการวัดเป็นรอบระยะ (Intermittent Monitoring) ในโรงพยาบาล โดยรวบรวมข้อมูลจากการศึกษา 24 ฉบับ และผู้ป่วยกว่า 40,000 ราย ผลการศึกษาพบว่าการติดตามสัญญาณชีพแบบต่อเนื่องมีความเป็นไปได้ในการใช้งานในหอผู้ป่วยทั่วไปและช่วยให้ตรวจพบสัญญาณเตือนของการทรุดลงของอาการได้เร็วยิ่งขึ้น อย่างไรก็ตาม คณะผู้วิจัยได้ชี้ให้เห็นถึงการทำทายนด้านสัญญาณเตือนผิดพลาด (False Alerts) และภาระงานของพยาบาล [20]

งานวิจัยนี้สนับสนุนแนวคิดของโครงการในการเฝ้าระวังผู้ป่วยระหว่างรอคิว แต่เน้นย้ำถึงความจำเป็นในการควบคุมอัตราการแจ้งเตือนผิดพลาด

2.12.2 งานวิจัยการติดตามสัญญาณชีพไร้สายด้วยอุปกรณ์สวมใส่

Weenk

และคณะ

(2019)

ได้ศึกษาการใช้อุปกรณ์สวมใส่ติดตามสัญญาณชีพแบบไร้สายและต่อเนื่องในหอผู้ป่วยทั่วไปเปรียบเทียบกับ การวัดตามรอบปกติของพยาบาล

โดยพบว่าอุปกรณ์สวมใส่สามารถตรวจพบช่วงเวลาที่ผู้ป่วยมีคะแนนเตือนภัยล่วงหน้า (Early Warning Score) สูงผิดปกติในระหว่างรอบที่ไม่มีการวัดของพยาบาลได้อย่างมีนัยสำคัญ [21] ผลการศึกษานี้ตอกย้ำถึงปัญหา “Waiting Gap” ที่โครงการมุ่งแก้ไข

อย่างไรก็ตาม

Areia

และคณะ

(2021)

ได้ทำการทบทวนวรรณกรรมอย่างเป็นระบบและการวิเคราะห์หอคัมภีร์ (Meta-analysis)

เกี่ยวกับผลกระทบของอุปกรณ์สวมใส่ติดตามสัญญาณชีพต่อเนื่อง

และสรุปว่าหลักฐานเชิงประจักษ์ในปัจจุบันยังไม่เพียงพอที่จะยืนยันได้อย่างเด็ดขาดว่าการใช้อุปกรณ์สวมใส่สามารถลดอัตราการย้ายเข้า ICU

หรือลดอัตราการเสียชีวิตได้อย่างมีนัยสำคัญทางสถิติ

เนื่องจากคุณภาพของเครื่องมือและความพร้อมของระบบในแต่ละสถานพยาบาลมีความแตกต่างกันสูง [22] ดังนั้น ในโครงการนี้จึงระบุอย่างระมัดระวังว่า อุปกรณ์สวมใส่ของโครงการทำหน้าที่ “สนับสนุนการเฝ้าระวังและช่วยตรวจจับความผิดปกติเบื้องต้น”

มิได้อ้างว่าสามารถลดอัตราการเสียชีวิตได้โดยตรง

2.12.3 งานวิจัยการตรวจจับการหกล้มด้วยอุปกรณ์สวมใส่

Mubashir, Shao, และ Seed (2013) ได้สำรวจและเปรียบเทียบวิธีการตรวจจับการหกล้ม

ทั้งแบบใช้อุปกรณ์สวมใส่ (Wearable Sensors), แบบใช้กล้องประมวลผลภาพ (Vision-based)

และแบบใช้เซนเซอร์แวดล้อม

(Ambient

Sensors)

และระบุว่าปัญหาท้าทายที่สุดคือการแยกแยะการหกล้มออกจากกิจกรรมประจำวัน (ADL)

ซึ่งมักสร้างแรงกระแทกความเร่งสูงเช่นเดียวกัน [10]

โครงการนี้จึงนำข้อสรุปดังกล่าวมาต่อยอดเป็นสเตตแมชีนหลายขั้นตอน (Multi-Stage FSM)

โดยต้องผ่านเงื่อนไข Free-fall, Impact และ Inactivity ต่อเนื่องกันเท่านั้น

2.12.4 งานวิจัยการคัดแยกผู้ป่วยด้วยการเรียนรู้ของเครื่อง

Levin

และคณะ

(2018)

ได้พัฒนาและทดสอบระบบคัดแยกผู้ป่วยฉุกเฉินอิเล็กทรอนิกส์ด้วย Machine Learning (e-triage) โดยใช้ข้อมูลจากโรงพยาบาลหลายแห่ง

และพบว่าแบบจำลองสามารถทำนายความเสี่ยงทางคลินิกและผลลัพธ์การรักษาได้แม่นยำกว่าการใช้เกณฑ์ ESI เพียงอย่างเดียว [15]

โครงการนี้นำแนวคิดการผสานรวมข้อมูลสัญญาณชีพและความอาการสำคัญมาประยุกต์ใช้ แต่สร้างจุดแตกต่างทางสถาปัตยกรรมด้วยการกำหนดให้พยาบาลเป็นผู้ตรวจสอบและยืนยันผลลัพธ์สุดท้าย (Human-in-the-loop)

2.12.5 งานวิจัยปัญญาประดิษฐ์ที่อธิบายได้ในระบบสุขภาพ

Amann และคณะ (2020) ได้วิเคราะห์ความสำคัญของ Explainable AI (XAI)

ในวงการแพทย์ และเสนอว่าความสามารถในการอธิบายผลต้องตอบสนองต่อผู้ใช้งานจริง (Healthcare Professionals) เพื่อให้เกิดความเข้าใจและความไว้วางใจ [17]

โครงการนี้จึงออกแบบให้ระบบปัญญาประดิษฐ์ไม่เพียงแสดงค่าผลการทำนาย (เช่น PINK 87%) แต่แสดงรายการเหตุผลทางสรีรวิทยาประกอบอย่างชัดเจน

2.12.6 งานวิจัยสถาปัตยกรรมระบบสุขภาพบนอินเทอร์เน็ตของสรรพสิ่ง

Islam และคณะ (2015) [18] และ Haghi และคณะ (2017) [19]

ได้นำเสนอกรอบสถาปัตยกรรม IoMT สำหรับการแพทย์ครบวงจร

โดยเน้นย้ำถึงการเชื่อมโยงอย่างไร้รอยต่อตั้งแต่ระดับเซนเซอร์ ไมโครคอนโทรลเลอร์

เครือข่ายสื่อสาร การประมวลผลบนคลาวด์ และส่วนติดต่อผู้ใช้งาน

ซึ่งสอดคล้องกับสถาปัตยกรรมของโครงการนี้ที่เชื่อมโยง Smartwatch เข้าสู่ Backend, AI

Decision Support, Nurse Dashboard, Queue System และ Patient Portal อย่างเป็นระบบ

ตารางที่ 2.3 สรุปและเปรียบเทียบผลการศึกษางานวิจัยที่เกี่ยวข้องกับโครงการ

ผู้วิจัย/ปี	หัวข้อการศึกษา	เทคโนโลยี/แนวคิดหลัก	ผลการศึกษาสำคัญ	การนำมาประยุกต์ในโครงการ
า				

ผู้วิจัย/ปี	หัวข้อการศึกษ	เทคโนโลยี/แนวคิดหลัก	ผลการศึกษาสำคัญ	การนำมาประยุกต์ในโครงการ
Rady et al. 1994 [5]	Shock Index in ED	อัตราส่วน HR/SBP	SI สะท้อนภาวะ Hemodynamic Instability ได้ดีกว่า BP เดี่ยว	ใช้ SI เป็นหนึ่งในดัชนีแจ้งเตือนความเสี่ยงวิกฤต
Allen 2007 [6]	PPG Clinical Measurement	ทัศนศาสตร์ทางชีวภาพ (Optical Biosignal)	อธิบายหลักการดูดกลืนแสงและข้อจำกัดของสัญญาณ PPG	เป็นพื้นฐานการพัฒนาอัลกอริทึมวัด HR และคำนวณ SpO ₂
Mubashir et al. 2013 [10]	Survey on Fall Detection	Wearable Sensors & Multistage FSM	การแยก fall จาก ADL ต้องใช้เงื่อนไขหลายระดับร่วมกัน	พัฒนาสแตตแมชีน 4 ชั้นตอนป้องกัน False Alarm
Islam et al. 2015 [18]	IoT Health Care Survey	Sensing, Network, Cloud Architecture	วางกรอบสถาปัตยกรรมระบบสุขภาพบน IoT ครบวงจร	นำมาออกแบบสถาปัตยกรรม IoMT 5 ระดับชั้น
Haghi et al. 2017 [19]	Wearables in Medical IoT	Wearable Hardware & Ecosystem	อุปกรณ์สวมใส่มีศักยภาพสูงในการติดตามสุขภาพระยะยาว	ใช้เป็นแนวทางออกแบบนาฬิกา Smartwatch ตรวจวัดต่อเนื่อง

ผู้วิจัย/ปี	หัวข้อการศึกษ	เทคโนโลยี/แนวคิดหลัก	ผลการศึกษาคัญ	การนำมาประยุกต์ในโครงการ
Levin et al. 2018 [15]	Machine Learning e-Triage	Supervised ML for Emergency Triage	ML ช่วยจำแนกความเสี่ยงและผลลัพธ์ทางคลินิกได้ละเอียดขึ้น	ออกแบบแบบจำลอง AI Triage จากสัญญาณชีพและข้อความ
Downey et al. 2018 [20]	Continuous vs Intermittent	Systematic Review on Continuous Vitals	การวัดต่อเนื่องช่วยตรวจพบการทรุดลงได้เร็วแต่ต้องคุมเตือนผิดพลาด	ตอบโจทย์แก้ปัญหา Waiting Gap พร้อมเพิ่มตัวกรองคุณภาพ
Weenk et al. 2019 [21]	Wireless Continuous Ward	Wireless Wearables in General Ward	ตรวจพบช่วง EWS สูงผิดปกติระหว่างรอบการวัดปกติของพยาบาล	ยืนยันสมมติฐานความจำเป็นในการเฝ้าระวังผู้ป่วยนอกโรค
Aman et al. 2020 [17]	Explainability in Health AI	Explainable AI (XAI) Framework	ความโปร่งใสและการอธิบายเหตุผลจำเป็นต่อการยอมรับทางคลินิก	ออกแบบให้ AI แสดงเหตุผลประกอบร่วมกับคำแนะนำ
Areia et al. 2021 [22]	Wearable Meta-analysis	Systematic Review & Meta-analysis	หลักฐานว่า wearable ลดการตายยังไม่สรุปชัดเจน ผลขึ้นกับความเสถียร	กำหนดขอบเขตระบบอย่างรัดกุม ไม่กล่าวอ้างสรรพคุณเกินจริง

ผู้วิจัย/ปี	หัวข้อการศึกษ	เทคโนโลยี/แนวคิดหลัก	ผลการศึกษาคัญ	การนำมาประยุกต์ในโครงการ
Sterg iou et al. 2023 [9]	Cuffless BP Validatio n	ESH Guidelines for Cuffless BP	การประมาณ BP ไร้ปลอกแขนต้องสอบเทียบเฉพาะและคว บคุมความเที่ยงตรง	กำหนดให้แสดงผลเป็น Estimated BP/Trend เพื่อการเฝ้าระวัง
โครง งาน นี้ (This Proje ct)	Hospital Queue & Wearabl e Monitori ng	IoMT + Multi-stage FSM + AI Triage + Human-in- the-loop	บูรณาการอุปกรณ์สวมใส่เข้ากับระบบ บคิวผู้ป่วยนอกโดยมีพยาบาลยืนยัน	ระบบต้นแบบบูรณาการครบ วงจร ลดช่องว่างการรอคอยอย่าง ปลอดภัย

2.12.7 ช่องว่างจากงานวิจัยเดิมและตำแหน่งเชิงนวัตกรรมของโครงการ

จากการทบทวนวรรณกรรมอย่างครอบคลุมพบว่างานวิจัยส่วนใหญ่ที่ผ่านมามักมุ่งเน้นการศึกษาองค์ประกอบใดองค์ประกอบหนึ่งแยกกันอยู่
างเป็นเอกเทศ เช่น การพัฒนาเซนเซอร์อุปกรณ์สวมใส่ [6], [7],
การสร้างอัลกอริทึมตรวจจับการหกล้ม [10], หรือการพัฒนาแบบจำลอง Machine Learning
เพื่อคัดแยกผู้ป่วยในแผนกฉุกเฉิน [15]
ขณะที่การนำเทคโนโลยีเหล่านี้มาบูรณาการเข้ากับกระบวนการจัดคิวผู้ป่วยนอก (Outpatient
Queue Management)
โดยเชื่อมโยงข้อมูลตั้งแต่ระดับฮาร์ดแวร์สวมใส่จนถึงส่วนติดต่อผู้ป่วยและแดชบอร์ดพยาบาล
ยังคงมีอยู่อย่างจำกัด

จุดเด่นและตำแหน่งเชิงนวัตกรรมของโครงการนี้
จึงมิได้อยู่ที่การคิดค้นเซนเซอร์ใหม่หรือการประดิษฐ์อัลกอริทึมปัญญาประดิษฐ์ขึ้นมาใหม่เพียงอย

างเดียว แต่อยู่ที่ “การบูรณาการระบบต้นแบบครบวงจร” (End-to-End Integrated Prototype) ที่เชื่อมโยงข้อมูลอย่างเป็นระบบ:

【 สายธารการบูรณาการระบบของโครงการ (End-to-End System Pipeline) 】

ผู้ป่วยสวมใส่อุปกรณ์ (Patient Wearable) → ตรวจสอบคุณภาพสัญญาณ (Signal Quality Index)
→ ส่งข้อมูลโทรมาตร (Telemetry via Wi-Fi/HTTPS) → ระบบหลังบ้านประมวลผล (Backend Analytics)
→ AI เสนอแนะความรุนแรง (AI Suggested Severity) → พยาบาลตรวจสอบและยืนยัน (Nurse Confirmation)
→ ปรับลำดับคิวแบบพลวัต (Dynamic Queue) → แสดงผลสถานะคิวบนเว็บแอปพลิเคชัน (Patient Portal)

โดยหัวใจสำคัญสูงสุด คือการยึดมั่นในสถาปัตยกรรม Human-in-the-loop

ซึ่งกำหนดให้ปัญญาประดิษฐ์ทำหน้าที่เป็นเพียง “ผู้ช่วยสนับสนุนการตัดสินใจ” และพยาบาลวิชาชีพเป็น “ผู้ตัดสินใจและยืนยันความรุนแรงขั้นสุดท้าย” เสมอ ซึ่งช่วยให้ระบบสามารถใช้ประโยชน์จากระบบอัตโนมัติในการเฝ้าระวังผู้ป่วยได้อย่างเต็มประสิทธิภาพ โดยไม่ลดทอนมาตรฐานความปลอดภัยและจริยธรรมทางการแพทย์

บรรณานุกรม

- [1] กรมการแพทย์ กระทรวงสาธารณสุข, คู่มือแนวทางการคัดแยกผู้ป่วยฉุกเฉิน (MOPH ED. Triage), พิมพ์ครั้งที่ 1, นนทบุรี: กรมการแพทย์, 2561.
- [2] N. Gilboy, P. Tanabe, D. Travers, and A. M. Rosenau, Emergency Severity Index (ESI): A Triage Tool for Emergency Department Care, Version 4, Implementation Handbook 2012 Edition, AHRQ Publication No. 12-0014, Rockville, MD: Agency for Healthcare Research and Quality, 2012.
- [3] H. Choi, J. S. Ok, and S. Y. An, “Evaluation of Validity of the Korean Triage and Acuity Scale,” Journal of Korean Academy of Nursing, vol. 49, no. 1, pp. 26–35, 2019, doi: 10.4040/jkan.2019.49.1.26.

- [4] Royal College of Physicians, National Early Warning Score (NEWS) 2: Standardising the Assessment of Acute-Illness Severity in the NHS, Updated report of a working party, London, UK: RCP, 2017.
- [5] M. Y. Rady, H. A. Smithline, H. Blake, R. Nowak, and E. Rivers, "A comparison of the shock index and conventional vital signs to identify acute, critical illness in the emergency department," *Annals of Emergency Medicine*, vol. 24, no. 4, pp. 685–690, 1994, doi: 10.1016/S0196-0644(94)70279-9.
- [6] J. Allen, "Photoplethysmography and its application in clinical physiological measurement," *Physiological Measurement*, vol. 28, no. 3, pp. R1–R39, 2007, doi: 10.1088/0967-3334/28/3/R01.
- [7] Analog Devices, MAX30102: High-Sensitivity Pulse Oximeter and Heart-Rate Sensor for Wearable Health Data Sheet, Rev. 1, Analog Devices Inc., Norwood, MA, USA, 2018.
- [8] Analog Devices, MAX32664: Ultra-Low Power Biometric Sensor Hub Data Sheet, Rev. 4, Analog Devices Inc., Norwood, MA, USA, 2022.
- [9] G. S. Stergiou, E. G. Mieke, R. Asmar, C. B. Rossi, et al., "European Society of Hypertension recommendations for the validation of cuffless blood pressure measuring devices," *Journal of Hypertension*, vol. 41, no. 12, pp. 2074–2087, 2023, doi: 10.1097/HJH.0000000000003483.
- [10] M. Mubashir, L. Shao, and N. L. Seed, "A survey on fall detection: Principles and approaches," *Neurocomputing*, vol. 100, pp. 144–152, 2013, doi: 10.1016/j.neucom.2011.09.037.
- [11] InvenSense Inc., MPU-6000 and MPU-6050 Product Specification, Revision 3.4, Document Number: PS-MPU-6000A-00, Sunnyvale, CA, USA, 2013.
- [12] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988, doi: 10.1016/0306-4573(88)90021-0.

- [13] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995, doi: 10.1007/BF00994018.
- [14] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001, doi: 10.1023/A:1010933404324.
- [15] S. Levin, M. Toerper, E. Hamrock, J. S. Hinson, S. Barnes, H. Gardner, A. Dugas, et al., "Machine-Learning-Based Electronic Triage More Accurately Differentiates Patients With Respect to Clinical Outcomes Compared With the Emergency Severity Index," *Annals of Emergency Medicine*, vol. 71, no. 5, pp. 565–574.e2, 2018, doi: 10.1016/j.annemergmed.2017.08.005.
- [16] World Health Organization, *Ethics and Governance of Artificial Intelligence for Health: WHO Guidance*, Geneva, Switzerland: World Health Organization, 2021. [Online]. Available: <https://www.who.int/publications/i/item/9789240029200>
- [17] J. Amann, A. Blasimme, E. Vayena, D. Frey, and V. I. Madai, "Explainability for artificial intelligence in healthcare: a multidisciplinary perspective," *BMC Medical Informatics and Decision Making*, vol. 20, Art. no. 310, 2020, doi: 10.1186/s12911-020-01332-6.
- [18] S. M. R. Islam, D. Kwak, M. H. Kabir, M. Hossain, and K.-S. Kwak, "The Internet of Things for Health Care: A Comprehensive Survey," *IEEE Access*, vol. 3, pp. 678–708, 2015, doi: 10.1109/ACCESS.2015.2437951.
- [19] M. Haghi, K. Thurow, and R. Stoll, "Wearable Devices in Medical Internet of Things: Scientific Research and Commercially Available Devices," *Healthcare Informatics Research*, vol. 23, no. 1, pp. 4–15, 2017, doi: 10.4258/hir.2017.23.1.4.
- [20] C. L. Downey, S. Chapman, R. Randell, J. M. Brown, and D. G. Jayne, "The impact of continuous versus intermittent vital signs monitoring in hospitals: A systematic review and narrative synthesis," *International Journal of Nursing Studies*, vol. 84, pp. 19–27, 2018, doi: 10.1016/j.ijnurstu.2018.04.013.
- [21] M. Weenk, M. Koeneman, T. H. van de Belt, L. J. L. P. G. Engelen, H. van Goor, and S. J. H. Bredie, "Wireless and continuous monitoring of vital signs in patients at the general

ward,” Resuscitation, vol. 136, pp. 47–53, 2019, doi: 10.1016/j.resuscitation.2019.01.017.

[22] C. Areia et al., “The impact of wearable continuous vital sign monitoring on deterioration detection and clinical outcomes in hospitalised patients: a systematic review and meta-analysis,” Critical Care, vol. 25, Art. no. 351, 2021, doi: 10.1186/s13054-021-03766-4.

[23] ราชกิจจานุเบกษา, “พระราชบัญญัติคุ้มครองข้อมูลส่วนบุคคล พ.ศ. 2562,” เล่ม 136 ตอนที่ 69 ก, หน้า 52–86, 27 พฤษภาคม 2562.

[24] Seeed Studio, “Getting Started with Seeed Studio XIAO ESP32C3,” Seeed Studio Wiki, 2023. [Online]. Available: https://wiki.seeedstudio.com/XIAO_ESP32C3_Getting_Started/